

Gibbsin otanta- ja Metropolis-Hastingsin algoritmit

Topias Karjalainen

11. toukokuuta 2020

Sisältö

1	Johdanto	2
2	Teoriaa	3
2.1	Perusmääritelmiä	3
2.2	Markovin ketjut	4
3	Markovin ketju Monte Carlo menetelmät	9
3.1	Gibbsin otanta-algoritmi	10
3.2	Metropolis–Hastings algoritmi	12
3.2.1	Yhteys Gibbsin otanta-algoritmiin	15
3.2.2	Ehdotusjakauman valinnasta	16
3.3	Yleisiä käytäntöjä MCMC-menetelmissä	17
3.4	Konvergenssi ja Diagnostiikka	17
3.4.1	Gelmanin \hat{R}	17
3.4.2	ESS	18
4	Laajempi esimerkki	20
5	Loppusanat	24

Luku 1

Johdanto

Tilastotieteissä *frekventistinen* koulukunta oli pitkään vallitseva koulukunta. Viimeaikoina kuitenkin suosiotaan on kasvattanut Bayesilainen koulukunta. Aiemmin Bayesiläinen päättely ei päässyt leviämään, sillä toisin kuin frekventistinen koulukunta, Bayesiläisyys ei tarjonnut suurinpaan osaan kysymyksiä analyyttisiä ratkaisuja. Vasta tietokoneiden aikakautena *Markovin ketju Monte Carlo -menetelmät* (MCMC-menetelmät) ovat antaneet mahdollisuuden ratkaista *posteriori*-jakaumat monimutkaisemmilta malleilta.

Monte Carlo menetelmän kehittäjä 50-luvulla *Los Alamosissa* työskennelleet *Nicholas Metropolis*, *Stanislav Ulam* ja yleisnero *John von Neumann*. Yleinen määritelmä Monte Carlo menetelmälle on toistuva satunnainen arvojen arpominen. Yksinkertainen esimerkki Monte Carlo simuloinnista on esimerkiksi π :n arvon estimointi arpomalla sattumanvaraisesti pisteitä tasosta, ja laskemalla kuinka moni niistä on ympyrän säteen sisällä.

Markovin ketjut ovat *stokastisia prosesseja*, jotka on nimetty venäläisen matemaatikon *Andrey Markovin* mukaan.

Tässä tutkielmassa tulen ensin antamaan lyhyen johdatuksen Markovin ketjuista ja selostan MCMC-menetelmien kannalta relevantin teorian. Tulen esittelemään lyhyesti kaksi algoritmia, joita käytetään MCMC-menetelmissä, *Gibbsin otanta-algoritmin* ja *Metropolis–Hastings algoritmin*. Esitän myös kaksi tärkeää diagnostiikkaa menetelmien tulosten arviointiin ja lopuksi vielä tarkastellaan hieman laajempaa käytännön esimerkkiä MCMC-algoritmista.

Luku 2

Teoriaa

2.1 Perusmääritelmiä

Määritellään ensiksi todennäköisyys. [Pii; Dur10]

Määritelmä 2.1. Olkoot Ω mielivaltainen epätyhjä joukko. σ -algebra perusjoukolla Ω on sen osajoukkojen joukkoperhe \mathcal{F} , joka toteuttaa ehdot:

1. $\emptyset \in \mathcal{F}$
2. jos $A \in \mathcal{F}$, niin $A^c \in \mathcal{F}$
3. jos jos $A_k \in \mathcal{F}$, kaikilla $k \in K$, missä K on numeroituva joukko, niin $\bigcup_{k \in K} A_k \in \mathcal{F}$

Määritelmä 2.2. Kuvaus \mathbf{P} liittää kuhunkin tapahtumaan A *todennäköisyyden*, joka on luku suljetulla välillä $[0,1]$ ja sille pätee:

1. $\mathbf{P}(\Omega) = 1$
2. Jos A on tapahtuma, niin sen komplementtitapahtuman A^c todennäköisyys on $\mathbf{P}(A^c) = 1 - \mathbf{P}(A)$
3. Jos $(A_k)_{k \in \mathbb{N}}$ ovat erillisiä tapahtumia, niin

$$\mathbf{P}\left(\bigcup_{k \in \mathbb{N}} A_k\right) = \sum_{k \in \mathbb{N}} \mathbf{P}(A_k)$$

Kuvausta \mathbf{P} kutsutaan *todennäköisyysmitaksi*.

Määritelmä 2.3. Olkoot \mathcal{A} σ -algebra joukolla X . Pari (X, \mathcal{A}) on *mitallinen avaruus*.

Määritelmä 2.4. Kolmikkoa $(\Omega, \mathcal{F}, \mathbf{P})$ kutsutaan *todennäköisyysavaruudeksi*.

Määritelmä 2.5. *Satunnaismuuttuja* X on (lähes) mielivaltainen kuvaus $X : \Omega \rightarrow S$, jossa S on *tilajoukko*.

2.2 Markovin ketjut

Esitellään ensiksi joitain perusasioita Markovin ketjuista, sillä ne eivät kuulu sellaisenaan opetussuunnitelmaan. Aloitetaan määrittelemällä stokastinen prosessi.[Pii]

Määritelmä 2.6. Jono $(X_n : n = 1, 2, 3, \dots)$ satunnaismuuttujia on diskreettiaikainen stokastinen prosessi.

Merkintä 2.7. Merkitään stokastista prosessia merkinnällä (X_n)

Esitetään nyt *Markovin ehto* diskreetille tila-avaruudelle määritelmässä 2.11, ja laajennetaan se jatkuvalle tila-avaruudelle määritelmässä 2.14. [RC05] Määritellään kuitenkin ensin siirtymäydin, eli jakauma, joka määrittelee tilojen välisten siirtymien todennäköisyydet. [Kle13, s. 180]

Määritelmä 2.8. Olkoot (S, \mathcal{S}) ja (Y, \mathcal{Y}) mitallisia avaruuksia. *Siirtymäydin* on funktio $T : S \times \mathcal{Y} \rightarrow [0, \infty[$, jolle pätee

- (i) $\forall s \in S : A \mapsto T(s, A)$ on todennäköisyyksimitta
- (ii) $\forall A \in \mathcal{Y} : s \mapsto T(s, A)$ on mitallinen

Diskreetissä tapauksessa siirtymäydin kutsutaan *siirtymämatriisiksi*, joka on

$$(2.9) \quad p_{ij} = \mathbf{P}(X_n = i | X_{n-1} = j), \quad \forall i, j \in S$$

Jatkuvassa tapauksessa ydin kuvaa ehdollista todennäköisyyttä $P(X_{n+1} \in A | X_n = x) = \int_A T(x, x') dx'$. Tälle pätee, että

$$(2.10) \quad \int_S T(x, x') dx' = 1$$

Määritelmä 2.11. Stokastinen prosessi (X_n) on *Markovin ketju* diskreetissä tila-avaruudessa, jos kaikilla alkuhetkillä m, n ja tiloilla $i, j \in S$ on voimassa

$$(2.12) \quad \begin{aligned} & \mathbf{P}(X_{n+1} = j | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = i) \\ &= \mathbf{P}(X_{n+1} = j | X_n = i) \end{aligned}$$

ja *siirtymätodennäköisyyksille* on voimassa

$$(2.13) \quad p_{ij} = \mathbf{P}(X_{n+1} = j | X_n = i) = \mathbf{P}(X_{m+1} = j | X_m = i)$$

Yhtälöä 2.12 kutsutaan *Markovin-ehdoksi* ja yhtälöä 2.13 taas kutsutaan *stationarisuusehdoksi*, mikä tarkoittaa, että siirtymätodennäköisyys tilojen i ja j välillä ei riipu ajasta m ja n , vaan pelkästään tiloista i ja j .

Määritelmä 2.14. Stokastinen prosessi (X_n) on *Markovin ketju* jatkuvassa tila-avaruudessa, jos kaikilla alkuhetkillä n , X_n :n ehdolliselle jakaumalle pätee

$$(2.15) \quad \mathbf{P}(X_{n+1} \in A | X_n = x_n, \dots, X_0 = x_0) = \mathbf{P}(X_{n+1} \in A | X_n = x_n)$$

Määritelmä 2.16. Satunnaismuuttujan X_0 jakaumaa kutsutaan *alkujakaumaksi*.

MCMC-menetelmien kannalta keskeinen ominaisuus Markovin ketjulle on sen tasapainojakauma (eng. *invariant distribution*). Siihen perustuu koko idea menetelmän takana. Esitetään seuraavaksi tämä ominaisuus, sekä määritellään toinen ominaisuus eli *kääntävä Markovin ketju* esittämällä ns. *detailed balance*-yhtälö, jota tarvitaan Metropolis-Hastingsin algoritmin tasapainojakauman olemassa olon osoittamiseen.

Määritelmä 2.17. Todennäköisyysjakauma $\pi = (\pi_i)_{i \in S}$ on diskreetin tila-avaruuden Markovin ketjun (X_n) tasapainojakauma, jos

$$(2.18) \quad \sum_{i \in S} \pi_i p_{ij} = \pi_j, \forall j \in S$$

Yhtälö 2.18 voidaan kirjoittaa myös muotoon

$$(2.19) \quad \pi^T \mathbf{P} = \pi^T$$

Jakauma π on jatkuvan tila-avaruuden Markovin ketjun (X_n) tasapainojakauma jos

$$(2.20) \quad \pi(y) = \int_S \pi(x) T(x, y) dx$$

Määritelmä 2.21. Markovin ketju on *kääntävä*, jos löytyy sellainen todennäköisyysjakauma $\lambda = (\lambda_i)_{i \in S}$, että

$$(2.22) \quad \lambda_i p_{ij} = \lambda_j p_{ji}, \forall i, j \in S$$

Määritelmä 2.23. Markovin ketju jatkuvassa tilajoukossa S on kääntävä, jos on olemassa sellainen todennäköisyys tiheys $\pi(x)$ joukossa S , että

$$(2.24) \quad \pi(x) T(x, y) = \pi(y) T(y, x), \forall x, y \in S$$

Kääntävällä Markovin ketjulla on sellainen mukava ominaisuus, että ketjun kääntyvyys on riittävä ehto tasapainojakauman olemassa ololle. Osoitamme tämän seuraavaksi.

Lause 2.25. Jos Markovin ketju on kääntävä, niin $\lambda = \pi$ on sen tasapainojakauma.

Todistus.

$$\sum_{i \in S} \lambda_i p_{ij} = \sum_{i \in S} \lambda_j p_{ji} = \lambda_j \sum_{i \in S} p_{ij} = \lambda_j$$

□

Lause 2.26. Jos Markovin ketju (X_n) on kääntynvä ja tilajoukko S on jatkuva, niin π on sen tasapainojakauma.

Todistus. Yhtälön 2.10 mukaan $\int_S T(y, x) dx = 1$, joten


$$(2.27) \quad \int_S \pi(x) T(x, y) dx = \int_S \pi(y) T(y, x) dx = \pi(y) \int_S T(y, x) dx = \pi(y)$$

□

Esimerkki 2.28. Pohditaan lyhyttä esimerkkiä, jossa tilajoukko on $S = \{ \text{”sataa”}, \text{”paistaa”} \}$. Määritellään siirtymätodennäköisyydet siirtymämatriisilla

$$\mathbf{P}^{(1)} = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$$

Tämä voidaan visualisoida kuvan 2.28 mukaisesti. Yhtälö 2.19 implikoi, että jakauma π



Kuva 2.1: Esimerkki 2.28

on siirtymämatriisin \mathbf{P} vasen ominaisvektori ($\pi^T \mathbf{P} = \lambda \pi^T$, jossa $\lambda = 1$). Tämä voidaan ratkaista numeerisesti, ja ratkaisu on $\pi^T = (0.4, 0.6)$. Helposti nyt nähdään, että 2.19 pätee.

Seuraavaksi esitellään lyhyeksi *syklinen siirtymäydin*, ja osoitetaan tulos, jota tarvitsemme Gibbsin otanta-algoritmin tasapainojakauman todistuksen yhteydessä.

Määritelmä 2.29. Markovin ketjuissa voimme myös tietyin ehdoin yhdistää siirtymätiheyksiä. Tällöin puhutaan syklisistä siirtymätiheyksistä. Diskreetissä tilanteessa siirtymätodennäköisyys

$$(2.30) \quad T_1 \dots T_d$$

voidaan määritellä matriisitulona $P_1 P_2 \dots P_d$. Jatkuvassa tapauksessa taas määritellään, että $T_c = T_1 \dots T_d$ on syklinen, jos

$$(2.31) \quad T_c(x, y) = \int_S T_1(x, z_1) T_2(z_1, z_2) \dots T_d(z_{d-1}, y) dz_1 \dots dz_{d-1}$$

Lause 2.32. *Jos tilajoukko S on diskreetti ja π^T on tasapainojakauma kaikille siirtymämatriiseille P_1, \dots, P_d , niin se on tasapainojakauma siirtymämatriisille $P = P_1 \dots P_d$.*

Todistus.

$$\pi^T P = \pi^T P_1 \dots P_d = \pi^T P_2 \dots P_d = \dots = \pi^T P_d = \pi^T$$

□

Lause 2.33. *Jos tilajoukko S on jatkuva ja π on tasapainojakauma kaikille siirtymätiheyksille T_1, \dots, T_d , niin se on tasapainojakauma siirtymätiheydelle $T_c = T_1 \dots T_d$*

Todistus.

$$(2.34) \quad \begin{aligned} \int_S \pi(x) T_c(x, y) dx &= \int_S \pi(x) \int_S T_1(x, z_1) T_2(z_1, z_2) \dots T_d(z_{d-1}, y) dz_1 \dots dz_{d-1} dx \\ &= \int_S T_2(z_1, z_2) \dots T_d(z_{d-1}, y) \underbrace{\int_S \pi(x) T_1(x, z_1) dx}_{\pi(z_1)} dz_1 \dots dz_{d-1} \\ &= \int_S T_3(z_2, z_3) \dots T_d(z_{d-1}, y) \underbrace{\int_S \pi(z_1) T_2(z_1, z_2) dz_1}_{\pi(z_2)} dz_2 \dots dz_{d-1} \\ &\vdots \\ &= \int_S \pi(z_{d-1}) T_d(z_{d-1}, y) dz_{d-1} \\ &= \pi(y) \end{aligned}$$

□

Käydään vielä nopeasti läpi muutama ominaisuus, joita tarvitaan kun haluamme osoittaa kappaleessa 3 algoritmien toimivan. [RC05; Koi09]

Määritelmä 2.35. Markovin ketju (X_n) , siirtymäytimellä $T(x, y)$ on *pelkistymätön* jos kaikilla $A \in \mathcal{T}$, joilla $P(A) > 0$, on olemassa sellainen n , että $T^n(x, A) > 0$ kaikilla $x \in S$

Käytännössä pelkistymättömyys tarkoittaa siis sitä, että jokaisesta tila-avaruuden kolkasta on mahdollista päästä joihinkin muuhun pisteeseen avaruutta, eli ketju ei voi jäädä jummiin johonkin alueelle.

Määritelmä 2.36. Markovin ketju (X_n) on *palautuva* jos

- (i) ketju (X_n) on pelkistymätön ja
- (ii) kaikilla $A \in \mathcal{T}$, joilla $\mathbf{P}(A) > 0$, $\mathbb{E}_x[\eta_A] = \infty$ kaikilla $x \in A$

Missä η_A on käyntien määrä joukossa A .

Palautuvalla ketju tarkoittaa sitä, että ketju palaa alueelle, jossa se on jo käynyt. Palautumista vahvempi ominaisuus on *Harris-palautuvuus*.

Määritelmä 2.37. Joukko A on Harris palautuva, jos $\mathbf{P}_x(\eta_A = \infty) = 1$ kaikilla $x \in A$. Markovin ketju (X_n) on Harris palautuva jos (X_n) on pelkistymätön, ja jokainen joukko A , jolla $\mathbf{P}(A) > 0$, on Harris palautuva.

Määritelmä 2.38. Markovin ketju (X_n) on jaksollinen, jos on olemassa erilliset osajoukot $A_1, A_2, \dots, A_d \subset S, d > 1$, että

$$(2.39) \quad T(x, A_{i+1}) = 1, \quad \forall x \in A_i, \quad i = 1, \dots, d-1$$

ja

$$(2.40) \quad T(x, A_1) = 1, \quad x \in A_d$$

Jos ketju ei ole jaksollinen, se on *jaksoton*.

Määritellään sitten vielä ergodisuus, joka on tärkeä ominaisuus Markovin ketjun tasapainojakauman olemassaolon kannalta.

Määritelmä 2.41. Markovin ketju (X_n) on ergodinen, jos se on pelkistymätön, jaksoton ja Harris-palautuva.

Ergodisuus on MCMC-menetelmien kannalta tärkeä ominaisuus, sillä se takaa Markovin ketjun (X_n) konvergoitumisen yksikäsitteisen tasapainojakaumaansa mistä tahansa tila-avaruuden S pisteestä. Tämän osoittaminen on melko hankalaa ja ylittää reilusti tämän tutkielman laajuuden, joten jätämme sen tekemättä.

Luku 3

Markovin ketju Monte Carlo menetelmät

Tässä luvussa aiomme esitellä MCMC-metodeja. Esittelemme alaluvussa 3.6 Gibbsin otanta-algoritmina tunnetun MCMC-menetelmän, ja sitten alaluvussa 3.2 esittelemme Metropolis–Hastings algoritmin. Osoitamme myös, että todellisuudessa alaluvun 3.6 algoritmi onkin todella vain erikoistapaus luvun 3.2 algoritmista. Pohditaan kuitenkin ensin menetelmän motivaatiota. [Koi09, s. 94] [RC05, s. 269]

Määritelmä 3.1. MCMC-menetelmiksi kutsutaan jakaumaa p simuloivia menetelmiä, jotka perustuvat siihen, että luodaan ergodinen Markovin ketju (X_n) , jolla on tasapainojakaumana jakauma p .

Ketjun ergodisuus takaa siis sen, että ketju konvergoituu jokaisesta tila-avaruuden pisteestä. Se takaa, että ketjun empiirinen keskiarvo

$$(3.2) \quad \mathfrak{J}_n = \frac{1}{n} \sum_{t=1}^n h(X_t)$$

konvergoituu odotusarvoon, eli

$$(3.3) \quad \lim_{n \rightarrow \infty} \mathfrak{J}_n \rightarrow \mathbb{E}_p[h(X_t)] = \int h(x)p(x)dx$$

Tällöin ketjun tiloja voidaan siis käsitellä i.i.d. otoksena tasapainojakaumasta.

Markovin ketjuille (ja useimmille MCMC-menetelmien tuottamille Markovin ketjuille) pätee myös keskeinen raja-arvolause 3.4.

$$(3.4) \quad \sqrt{n}(\mathfrak{J}_n - \mathbb{E}_p[h(X_t)]) \rightarrow N(0, \sigma_h^2) \quad \text{kun } n \rightarrow \infty$$

jossa

$$(3.5) \quad \sigma_h^2 = \text{var}_p(h(X_0)) + 2 \sum_{t=1}^{\infty} \text{cov}_p(h(X_0), h(X_t))$$

Menetelmän ydin on siis rakentaa systemaattisella tavalla Markovin ketju, jonka tasapainojakaumana on haluamamme simuloitava jakauma. Tämän voisi kuvitella olevan kovin vaikeaa, mutta yllättävästi se onkin melko triviaalia.

3.1 Gibbsin otanta-algoritmi

Gibbsin otanta-algoritmi on tapa simuloida bayesiläistä moniulotteista posteriorijakautta (eli ulottuvuuksia vähintään 2), kun suora otanta on hankalaa. Algoritmi on nimetty amerikkalaisen fyysikon, *Josiah Willard Gibbsin* (1839-1903) mukaan, mutta sen todellinen kehittäjä on veljekset *Donald Geman* (1943-) ja *Stuart Geman* (1949-) vuonna 1984 artikkelissa *Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images*.

Määritelmä 3.6. Olkoot θ parametrivektori, joka jaetaan d :hen osaan tai osavektoriin, eli $\theta = (\theta_1, \theta_2, \dots, \theta_d)$. Gibbsin otanta-algoritmi määritellään seuraavanlaisesti:

1. Valitaan satunnainen indeksi j jolle $1 \leq j \leq d$
2. Arvotaan uusi tila jokaiselle osavektorille θ_j ehdollistamalla se jokaiselle muulle parametrille, eli vedetään arvot $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ jakaumista

$$(3.7) \quad p(\theta_j | \theta_{-j}^{(n-1)}, y)$$

missä $\theta_{-j}^{(n-1)}$ on kaikki muut parametrin θ komponentit paitsi j . komponentti, näiden tämänhetkisillä arvoilla eli

$$\theta_{-j}^{(n-1)} = (\theta_1^{(n-1)}, \dots, \theta_{j-1}^{(n-1)}, \theta_{j+1}^{(n-1)}, \dots, \theta_d^{(n-1)})$$

Yleensä ylläolevassa määritelmässä kohdassa 1. ei arvota uutta järjestystä, vaan järjestys päätetään alussa, ja sitä pidetään koko algoritmin ajan samana. Tätä kutsutaan *systemaattiseksi Gibbsin otanta-algoritmiksi* (*systematic scan Gibbs sampler*).

Lause 3.8. Määritelmän 3.6 mukaisen algoritmin tuottama Markovin ketju on jaksoton, pelkistymätön ja Harris palautuva ja sillä on sitten yksikäsitteinen tasapainojakauma $p(\theta)$. [Koi09]

Todistus. Voitaisiin osoittaa, että määritelmän 3.6 algoritmin tuottama Markovin ketju on ergodinen, ja täten konvergoituu tasapainojakaumaan. Ohitetaan se tässä, sillä todistus on melko tekninen.

Olkoot $\theta^{(n-1)}$ parametrin alkuperäisen tila, ja $\theta_j^{(n)}$ uusi j :nnen parametrin tila. Nyt $\theta^{(n-1)}$ ja $\theta_j^{(n)}$ yhteistiheysfunktio on kertolaskusäännöllä.

$$(3.9) \quad p(\theta^{(n-1)}) p_j(\theta_j^{(n)} | \theta_{-j}^{(n-1)})$$

Nyt voidaan integroida

$$\begin{aligned}
(3.10) \quad \int p(\theta^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} &= \int p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} \\
&= p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)}) \int p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} \\
&= p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)}) \\
&= p(\theta_j^{(n)}, \theta_{-j}^{(n-1)})
\end{aligned}$$

Eli Gibbs otanta-algoritmin päivitys ei muuta jakaumaa. Nyt voidaan soveltaa lausetta 2.33, jolloin voidaan todeta, että koska p tasapainojakauma jokaiselle $p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})$, niin se on tasapainojakauma niiden yhteis siirtymätiheydelle

$$(3.11) \quad T = \prod_{j=1}^d p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})$$

□

Ohitetaan Gibbsin otanta-algoritmin kohdalla toistaiseksi esimerkit, ja palataan siihen kappaleessa 4, jossa tarkastelemme laajempaa esimerkkiä lineaarisen regression parissa. Toteutamme tämän Gibbsin otanta-algoritmina.

Gibbsin otanta-algoritmin vaatimus ehdollisista jakaumista voi vaikuttaa jokseenkin rajoittavalta, sillä joskus voidaan tutkia mallia, jolle on vaikea laskea ehdolliset jakaumat. Tällöin voidaan kuitenkin pienin muunnoksia hyödyntää Gibbsin otanta-algoritmia hyödyntämällä seuraavaa määritelmää 3.12. [RC05, s. 374]

Määritelmä 3.12. Olkoot p tiheysfunktio. Tiheysfunktio λ , joka täyttää ehdon

$$(3.13) \quad \int_Z \lambda(x, z)dz = p(x)$$

kutsutaan p :n täydellistymäksi (*completion*).

Tiheys λ valitaan siten, että sille voi ratkaista ehdolliset jakaumat. Nyt Gibbsin otanta-algoritmi voidaan toteuttaa käyttämällä jakaumaa λ ja sen ehdollisia jakaumia. Lauseen 3.8 tulos pätee myös tässä tapauksessa. Tällöin malliin tulee toki uusi parametri z , joka on täysin turha mallin kannalta, mutta avustaa simuloinnissa.

3.2 Metropolis–Hastings algoritmi

Metropolis–Hastings algoritmi on kehittelijöidensä *Nicholas Metropolin* (1915-1999) ja *Wilfred Keith Hastingsin* (1930-2016) mukaan nimetty MCMC-menetelmä, jolla voidaan simuloida bayesiläisessä analyysissä käytettäviä posteriori jakaumia myös silloin kun tiheys on mahdotonta määrittää analyttisesti.

Algoritmin pohjan kehittivät *Stanislav Ulam* ja Metropolis työskennellessään *Los Alamosissa* ja myöhemmin Metropolis kehitti nykyään *Metropolis-algoritmina* tunnettua algoritmia ja esittelivät sen artikkelissa *Equation of state calculations by fast computing machines* [Met53]. Tämä versio algoritmista vaati, että pian esiteltävä *ehdotusjakauma* on symmetrinen. Myöhemmin *Hastings* laajensi algoritmin koskemaan myös epäsymmetrisiä ehdotusjakaumia artikkelissa *Monte Carlo Sampling Methods Using Markov Chains and Their Applications*. Esitämme jälkimmäisen version algoritmista, sillä edellinen seuraa jälkimmäisestä suoraan.

Merkintä 3.14. TN-jakauma $J_n(\cdot|\cdot)$ on niin sanottu *ehdotusjakauma* (*proposal distribution*, *jumping distribution*), josta *MH-algoritmista* arvotaan ehdotustila.

Nyt kun ehdotusjakauma on määritelty, voidaan määritellä Metropolis-Hastingsin algoritmi seuraavanlaisesti [Gel+13, s.278-279]

Määritelmä 3.15. Metropolis–Hastings algoritmi on seuraavanlainen

1. Valitaan aloitus tila θ_0 ja asetetaan $n = 1$
2. Generoidaan kandidaatti tila θ' satunnaisesti ehdotusjakaumasta $J_n(\theta'|\theta^{(n-1)})$
3. Lasketaan suhde

$$r = \frac{p(\theta'|y)/J_n(\theta'|\theta^{(n-1)})}{p(\theta^{(n-1)}|y)/J_n(\theta^{(n-1)}|\theta')}$$

4. Asetetaan

$$\theta^{(n)} = \begin{cases} \theta', & \text{todennäköisyydellä } \min(r, 1) \\ \theta^{(n-1)}, & \text{muuten} \end{cases}$$

Lause 3.16. Määritelmän 3.15 algoritmi tuottaa Markovin ketjun jolla on uniikki tasapainojakauma $p(\theta)$

Todistus. Todistus nojautuu Markovin ketjun kääntyvyysominaisuuteen (2.21) ja (2.23), eli

$$(3.17) \quad T(\theta^{(n)}|\theta^{(n-1)})p(\theta^{(n-1)}) = T(\theta^{(n-1)}|\theta^{(n)})p(\theta^{(n)})$$

joka on siis riittävä ehto tasapainojakauman olemassaololle. Mietitään kahta tapausta: (1) $\theta^{(n)} \neq \theta^{(n-1)}$ ja (2) $\theta^{(n)} = \theta^{(n-1)}$. Tapauksen (2) siirtymä voi tapahtua kahdella tavalla. Josko kohdassa 4. ehdotus θ' hylätään, tai se hyväksytään, mutta osutaan sattumanvaraisesti takaisin samaan kohtaan. Kuitenkin selvästi nähdään, että ehto 3.17 pätee tilanteessa (2).

Tilanteessa (1) siirtymätodennäköisyys pisteestä $\theta^{(n-1)}$ pisteeseen $\theta^{(n)}$ on

$$(3.18) \quad T(\theta^{(n)}|\theta^{(n-1)}) = J_n(\theta^{(n)}|\theta^{(n-1)}) \min \left(\frac{p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)})}{p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)})}, 1 \right)$$

Jota voidaan muokata helposti muotoon

$$(3.19) \quad \begin{aligned} T(\theta^{(n)}|\theta^{(n-1)}) &= J_n(\theta^{(n)}|\theta^{(n-1)}) \min \left(\frac{p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)})}{p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)})}, 1 \right) \\ &= \frac{1}{p(\theta^{(n-1)})} \min \left(p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}), p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}) \right) \end{aligned}$$

Toistamalla ylläoleva siirtymätodennäköisyydelle pisteestä $\theta^{(n)}$ pisteeseen $\theta^{(n-1)}$ havaitaan, että

$$(3.20) \quad T(\theta^{(n-1)}|\theta^{(n)}) = \frac{1}{p(\theta^{(n)})} \min \left(p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}), p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}) \right)$$

lauseke on symmetrinen. Kerrotaan yhtälö (3.19) termillä $p(\theta^{(n-1)})$ ja hyödynnetään ominaisuutta (3.20), jolloin

$$\begin{aligned} T(\theta^{(n)}|\theta^{(n-1)})p(\theta^{(n-1)}) &= \frac{1}{p(\theta^{(n-1)})} \min \left(p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}), p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}) \right) p(\theta^{(n-1)}) \\ &= \frac{1}{p(\theta^{(n)})} \min \left(p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}), p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}) \right) p(\theta^{(n)}) \\ &= T(\theta^{(n-1)}|\theta^{(n)})p(\theta^{(n)}) \end{aligned}$$


Eli myös tapauksessa (1) yhtälö (3.17) pätee. □

Esimerkki 3.21. Ajatellaan kuvitteellista tapausta, jossa meillä jatkuva kaksiulotteinen todennäköisyysjakauma, jonka tiheysfunktio on

$$(3.22) \quad p(\theta) \propto \exp(-5|\theta_1^2 + \theta_2^2 - 1|)$$


joka muodostaa regasmaisen 2-ulotteisen jakauman. Valitaan ehdotusjakaumaksi $J_n(\theta^{(n)}|\theta^{(n-1)})$ 2d-multinormaalijakauma

$$(3.23) \quad J_n(\theta^{(n)}|\theta^{(n-1)}) \sim N(\theta^{(n-1)}, \sigma^2 I_2)$$



Kuva 3.1: Vasemmalla: $(5,5)$. Keskellä: $(0,0)$ Oikealla: tiheystestimaatti (huomaa eri skaalaa).

jossa I_2 on 2×2 yksikkömatriisi ja olkoot $\sigma^2 = 0.01$. Nyt Metropolis-Hastingsin algoritmin avulla voidaan simuloida jakaumaa $p(\theta)$ algoritmilla 3.15. Simuloidaan kaksi Markovin ketjua asettamalla aloitustiloiksi $(0,0)$ ja $(5,5)$, kummastakin 10 000 tilaa. Simuloimme myös 200 000 pistettä aloitusarvolla $(0,0)$, joista luodaan tiheystestimaatti. Tulokset löytyy kuvasta 4.2. Kahdessa ensimmäisessä kuvassa viiva on ensimmäisen 250 pisteen polku. Selvästi nähdään, että aloituspisteellä ei ole väliä. Markovin ketjun tasapainojakauma on sama huolimatta aloituspisteestä.



Kuva 3.2: Esimerkin 3.24 tulokset

Esimerkki 3.24. Otetaan toisena esimerkkinä klassinen tapaus, jossa oletetaan, että havainnot ovat jakautuneet *Bernoulli-jakauman* mukaan, $y_i \sim \text{Bernoulli}(\theta)$, ja että prior

on tasajakauma. Tällöin tiedetään, että analyttinen posteriori on

$$p(\theta|y_i) = \text{Beta}\left(\sum_{i=1}^n y_i + 1, n - \sum_{i=1}^n y_i + 1\right)$$

Valitaan hieman eksoottinen ehdotusjakauma esimerkin vuoksi:

$$(3.25) \quad J_n(\theta_n|\theta_{n-1}) \sim \begin{cases} \text{Unif}(\theta_{n-1}, 1) & \text{kun } \theta_{n-1} < 0.5 \\ \text{Unif}(0, \theta_{n-1}) & \text{kun } \theta_{n-1} \geq 0.5 \end{cases}$$

Toisin kuin esimerkissä 3.21, nyt ehdotusjakauma ei olekkaan symmetrinen.

Oletetaan että, meillä on havainnot $(1, 1, 1, 0, 0, 1, 0, 0, 0, 0)$ ja tarkastellaan sekä analyttistä että MH-algoritmin tuottamaa jakaumaa ja niiden eroja.

Kuvasta 3.2 nähdään esimerkin tulokset. Huomataan, että vaikka ehdotusjakauma on melko kummallinen, niin kuitenkin riittävän monella iteraatiolla saavutetaan tasapainojakauma. Huomaa, että vasemmassa kuvaajassa on vihreällä simulaatio keskiarvo, ja punaisella analyttinen keskiarvo, mutta nämä arvot ovat niin lähellä toisiaan, että viivat ovat päällekkäin.

3.2.1 Yhteys Gibbsin otanta-algoritmiin

Kuten jo totesimme aiemmin, Gibbsin otanta-algoritmin voi esittää Metropolis-Hastings algoritmin erityis tilanteena, jossa hyväksymis todennäköisyys on 1.

Lause 3.26. *Gibbsin otanta-algoritmi on erityistapaus Metropolis-hastings algoritmista.*

Todistus. Määritellään MH-algoritmin iteraatio n niin, että se sisältää d askelta, ja jossa iteraation n askel j kuvaa parametriosavektorin θ_j päivitystä ehdollistettuna kaikilla muilla parametrin θ :n elementeillä. Tällöin ehdotusjakauma $J_{j,n}$ iteraation n askeleessa j , voidaan määrittää siten, että se ehdottaa vain tiloja, jotka muuttaa vain parametria θ_j . Eli:

$$(3.27) \quad J_{j,n}^{Gibbs}(\theta^*|\theta^{(n-1)}) = \begin{cases} p(\theta_j^*|\theta_{-j}^{(n-1)}) & \text{kun } \theta_{-j}^* = \theta_{-j}^{(n-1)} \\ 0 & \text{muulloin} \end{cases}$$

Nyt voidaan kirjoittaa suhde r iteraation n j :nen askeleen kohdalla muotoon

$$\begin{aligned}
 r &= \frac{p(\theta^*)/J_{j,n}^{Gibbs}(\theta^*|\theta^{(n-1)})}{p(\theta^{(n-1)})/J_{j,n}^{Gibbs}(\theta^{(n-1)}|\theta^*)} \\
 &= \frac{p(\theta^*)/p(\theta_j^*|\theta_{-j}^{(n-1)})}{p(\theta^{(n-1)})/p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})} \\
 &= \frac{p(\theta_{-j}^{(n-1)})}{p(\theta_{-j}^{(n-1)})} \\
 &= 1
 \end{aligned}
 \tag{3.28}$$

Eli määrittelemällä MH-algoritmillemme siirtymäjakauma sillä tavalla, että se vastaa Gibbsin otanta-algoritmia, siirtymän hyväksymistodennäköisyydeksi tulee 1. \square

3.2.2 Ehdotusjakauman valinnasta

Kummassakin kappaleen 3.2 esimerkissä valitsimme ehdotusjakauman melko satunnaisesti. Varsinkin esimerkissä 3.24 se on erittäin epätavallinen, mistä syystä hyvän approksimaation saavuttaminen vie todella monta iteraatiota. Yleensä jos haluamme oikeasti tehokkaasti ja ekonomisesti simuloida jakaumia esitetyllä algoritmeilla, haluamme valita ehdotusjakauman jollakin järkevällä, systemaattisella tavalla, joka minimoisi tarvittavien iteraatioiden määrän.

Yleisesti ottaen hyvällä ehdotusjakaumalla on muutama ominaisuus[Gel+13, s. 280]

1. Kaikilla θ :n arvoilla on helppo arpoa arvo $J(\theta'|\theta)$
2. Suhde r on helppo laskea
3. Siirtymät ovat tarpeeksi pitkiä. Muuten Markovin ketju etenee liian hitaasti ja hyvän estimaatin saaminen kestää liian pitkään.
4. Siirtymiä ei hylätä liian usein. Muuten Markovin ketju ei etene vaan seisoo paikallaan.

Lisäksi simulointia voidaan nopeuttaa mm. käyttämällä adaptiivista ehdotusjakaumaa, eli toisinsanoen ehdotusjakaumaa muunnellaan riippuen ketjun liikkeistä. [Gel+13, s. 295]

3.3 Yleisiä käytäntöjä MCMC-menetelmissä

Usein on tapana simuloida useampi kuin yksi ketju kustakin tapauksesta. Tällöin asetetaan näiden ketjujen aloitustilat eriäviksi, jotta saadaan vähennettyä aloitustilan vaikutusta lopputulokseen.

Toinen yleinen käytäntö on jättää ketjun alkupäästä jonkin verran tiloja huomiotta, sillä ketjun alkupäässä ei se ei välttämättä ole vielä saavuttanut tasapainojakaumaa. Tätä kutsutaan *Burn-in periodiksi*.

Joskus taas on hyvä tapa pudottaa joka n :s tila ketjusta. Tilojen tiputtaminen ei vaikuta tasapainojakaumaan, kunhan ketju vain on saavuttanut sen. Tilojen tiputtamista on hyötyä jos mallissa on paljon parametreja, jolloin tietokoneessa voi tulla ongelmia tilan kanssa.

3.4 Konvergenssi ja Diagnostiikka

Kappaleissa 3.6 ja 3.2 esiteltyjen algoritmien kohdalla voi herätä kysymys, että mikä on riittävä määrä iteraatioita, jotta Markovin ketju on saavuttanut tasapainojakaumansa ja otanta on riittävän hyvä aproksimaatio posteriorijakaumasta. Esimerkiksi kun katsotaan kuvan 4.2 vasemman puolen kuvan punaista polkua, niin voidaan sanoa, että se ei ole vielä saavuttanut tasapainojakaumaa sillä haluttu jakauma tunnetaan, mutta tätä ei välttämättä osata sanoa suoraan.

Toinen yleinen ongelma, joka kaipa pohdintaa on se, että ketjujen sisällä on korrelaatiota, mikä vaikeuttaa päättelyä simuloinnin tuloksista. Otannat eivät siis ole välttämättä täysin riippumattomia.

3.4.1 Gelmanin \hat{R}

Yksi yleisimmistä estimaattoreista, joita käytetään MCMC-metodeissa Markovin ketjujen konvergenssin arvioimiseen on *Andrew Gelmanin* \hat{R} . Se mittaa ketjujen sisäistä sekoittumista (eng. *mixing*) ja erillisten ketjujen välistä sekoittumista.[Gel92; Gel98]

Määritelmä 3.29. *Gelmanin* \hat{R} lasketaan jakamalla ensin jokin määrä simuloituja ketjua erillisillä aloituspisteillä keskeltä kahtia. Olkoon nyt m ketjujen määrä jaon jälkeen ja n ketjujen pituus. Olkoot $\psi_{ij}(i = 1, \dots, n; j = 1, \dots, m)$ tila i ketjussa j . Nyt merkitään

$$(3.30a) \quad B = \frac{n}{m-1} \sum_{j=1}^m (\bar{\psi}_{\cdot j} - \bar{\psi}_{\cdot \cdot})^2, \quad \text{jossa}$$

$$(3.30b) \quad \bar{\psi}_{.j} = \frac{1}{n} \sum_{i=1}^n \psi_{ij}$$

$$(3.30c) \quad \bar{\psi}_{..} = \frac{1}{m} \sum_{j=1}^m \bar{\psi}_{.j}$$

Ja merkitään

$$(3.31) \quad W = \frac{1}{m} \sum_{j=1}^m s_j^2, \text{ jossa } s_j^2 = \frac{1}{n-1} \sum_{i=1}^n (\psi_{ij} - \bar{\psi}_{.j})^2$$

Jossa siis B on ketjujen välinen varianssi (*between sequence*) ja W on ketjujen sisäinen varianssi (*within sequence*). Näiden painotettuna keskiarvona saadaan estimaattori parametrin ψ marginaaliselle posteriorivarianssille

$$(3.32) \quad \hat{\sigma}^+(\psi|y) = \frac{n-1}{n} W + \frac{1}{n} B$$

Nyt \hat{R} voidaan määritellä

$$(3.33) \quad \hat{R} = \sqrt{\frac{\hat{\sigma}^+(\psi|y)}{W}}$$

Gelmanin \hat{R} mittaa sitä miten paljon kullakin hetkellä ψ :n jakauma voisi supistua, jos simulaatioiden annettaisiin jatkua loputtomasti. Eli siis kun $\hat{R} \approx 1$, niin voidaan sanoa, että Markovin ketju on todennäköisesti saavuttanut tasapainojakaumansa, sillä tällöin eri pisteitä aloitettujen ketjujen välinen varianssi on vakaantunut.

Tällä diagnostiikalla on kuitenkin ongelmansa ja rajoitteensa. Se saattaa virheellisesti diagnosoida konvergoituneen ketjun esimerkiksi jos ketjulla on pitkät hännät. Sen takia käytetäänkin mielummin muita diagnostiikka keinoja. Esimerkiksi *Stan* käyttää korjattua \hat{R} diagnostiikkaa. [Veh+19]

3.4.2 ESS

Toinen hyödyllinen diagnostiikka MCMC-menetelmissä on niin sanottu *effective sample size* (*ESS*), joka mittaa sitä kuinka monta efektiivisesti riippumatonta otosta ketjussa on. Tämä tarkoittaa siis sitä, että se mittaa kuinka paljon ketjun autokorrelaatio vaikuttaa keskivirheeseen verrattuna täysin riippumattomiin otoksiin.

Määritelmä 3.34. ESS lasketaan kaavalla

$$(3.35) \quad \hat{n}_{\text{eff}} = \frac{mn}{1 + 2 \sum_{t=1}^T \hat{\rho}_t}$$

jossa

$$(3.36a) \quad \hat{\rho}_t = 1 - \frac{V_t}{2\hat{\sigma}^+}$$

$$(3.36b) \quad V_t = \frac{1}{m(n-t)} \sum_{j=1}^m \sum_{i=t+1}^n (\psi_{ij} - \psi_{i-t,j})^2$$

Kaavan (3.36a) $\hat{\sigma}^+$ saadaan kaavasta (3.32). Termissä $\sum_{t=1}^T \hat{\rho}_t$ autokorrelaatioita summataan, kunnes kahden peräkkäisen kovariaatin summa on negatiivinen [Gey92].

Luku 4

Laajempi esimerkki

Tarkastellaan vielä lopuksi laajempaa esimerkkiä. Tarkastellaan normaalia lineaarista regressiomallia. Käytetään R:stä löytyvää `airquality` aineistoa New Yorkin ilmanlaadusta. Sovitetaan aineistoon bayesilainen lineaarinen malli

$$(4.1) \quad \text{Ozone} = \beta_0 + \beta_1 \text{Solar.R} + \beta_2 \text{Wind}$$

Sovitetaan tämä malli Gibbsin otanta-algoritmin avulla. Sitä varten meidän on ensiksi määriteltävä marginaaliset ehdolliset jakaumat parametreille.

Määritellään ensiksi malli. Merkitään $\tau = 1/\sigma^2$, $\theta = (\beta_0, \beta_1, \beta_2, \tau)$

$$(4.2) \quad \begin{aligned} y_i | \beta_0, \beta_1, \beta_2, \tau &\sim N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau) \\ \beta_0 | \mu_0, \tau_0 &\sim N(\mu_0, 1/\tau_0) \\ \beta_1 | \mu_1, \tau_1 &\sim N(\mu_1, 1/\tau_1) \\ \beta_2 | \mu_2, \tau_2 &\sim N(\mu_2, 1/\tau_2) \\ \tau | \alpha, \gamma &\sim \text{Gamma}(\alpha, \gamma) \end{aligned}$$

Muodostetaan uskottavuusfunktio

$$(4.3) \quad L(y|\theta) = \prod_{i=1}^N N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau)$$

Posterioirijakauman tiheysfunktio on siten laskettavissa verrannollisuudella

$$(4.4) \quad p(\theta|y) \propto p(\beta_0)p(\beta_1)p(\beta_2)p(\tau) \prod_{i=1}^N N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau)$$

Tästä saadaan sitten johdettua marginaaliset jakaumat otanta-algoritmia varten

$$\begin{aligned}
(4.5) \quad & \beta_0 | \beta_1, \beta_2, \tau_0, \tau, \mu_0, x, y \sim N \left(\frac{\tau_0 \mu_0 + \tau \sum_{i=1}^N (y_i - \beta_1 x_{i1} - \beta_2 x_{i2})}{\tau_0 + \tau N}, \frac{1}{\tau_0 + \tau N} \right) \\
& \beta_1 | \beta_0, \beta_2, \tau_1, \tau, \mu_1, x, y \sim N \left(\frac{\tau_1 \mu_1 + \tau \sum_{i=1}^N (y_i - \beta_0 - \beta_2 x_{i2}) x_{i1}}{\tau_1 + \tau \sum_{i=1}^N x_{i1}^2}, \frac{1}{\tau_1 + \tau \sum_{i=1}^N x_{i1}^2} \right) \\
& \beta_2 | \beta_0, \beta_1, \tau_2, \tau, \mu_2, x, y \sim N \left(\frac{\tau_2 \mu_2 + \tau \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{i1}) x_{i2}}{\tau_2 + \tau \sum_{i=1}^N x_{i2}^2}, \frac{1}{\tau_2 + \tau \sum_{i=1}^N x_{i2}^2} \right) \\
& \tau | \beta_0, \beta_1, \beta_2, \alpha, \gamma, x, y \sim \text{Gamma} \left(\alpha + \frac{N}{2}, \gamma + \frac{N}{2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2})^2 \right)
\end{aligned}$$

Asetetaan hyperparametrit $\mu_0 = 80, \mu_1 = 0, \mu_2 = -5, \tau_0 = 1/50, \tau_1 = 1/50, \tau_2 = 1/50, \alpha = 5, \gamma = 0.01$. Parametrit on valittu sen mukaan, että ne asettavat jakauman moodin lähelle arvioitua sijaintia ja toisaalta eivät ole kovin informatiivisia vaan paksu häntäisiä. Simuloidaan nyt tästä Gibbsin otanta-algoritmillä yhtälöitä 4.5 käyttäen 8 ketjua, kunkin pituus 2 000. Burnin-periodi olkoot 1 000. Yhteensä siis meillä on 16 000 otosta.

θ	Mean	SD	2.5%	25%	50%	75%	97.5%
β_0	78.89544	5.61842	67.97969	75.14744	78.89385	82.64874	89.86483
β_1	0.09675	0.02263	0.05196	0.08130	0.09688	0.11218	0.14106
β_2	-5.48880	0.51291	-6.48407	-5.83627	-5.49158	-5.13095	-4.48973
τ	0.00177	0.00023	0.00136	0.00161	0.00176	0.00192	0.00226


Taulukko 4.1: Tulokset regressiosta

θ	\hat{R}	\hat{n}_{eff}
β_0	1.00	778
β_1	1.00	1177
β_2	1.01	902
τ	1.00	7656

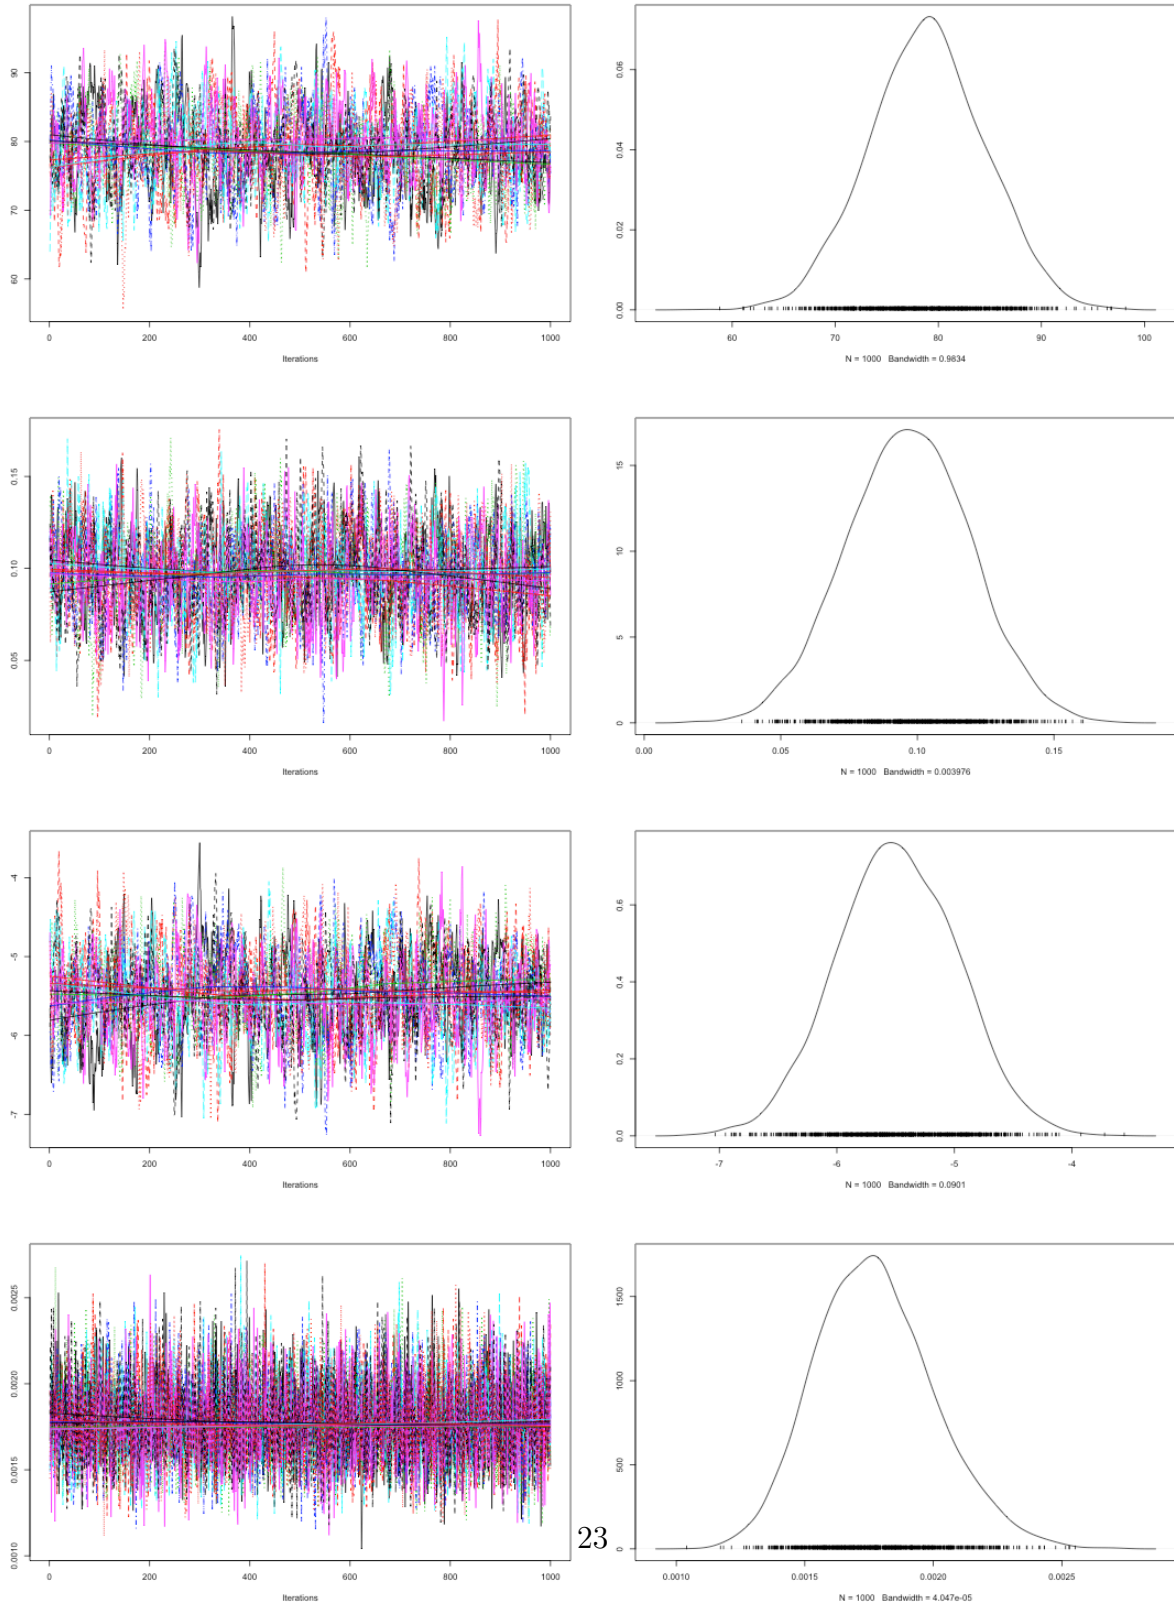
Taulukko 4.2: Diagnostiikka

Taulukoissa 4.1 ja 4.2 nähdään tulokset ja MCMC-diagnostiikat, joista puhuttiin aiemmin. Nähdään, että ketjut näyttäisivät konvergoituneen, mikä ei sinänsä ihmetytä lainkaan, sillä simulaatio määrämme on valtava. Yhteensä burn-in periodin jälkeen otoksia on 8000.

Mielenkiintoista on nähdä, että kuvassa 4.2 ketju parametrille $1/\tau$ on aivan ernäköinen kuin muille parametreille. Otoksia on yhtä paljon kaikissa, mutta parametrin $1/\tau$ ketju näyttää siltä, että otoksia olisi enemmän. Tämä toki nähdään myös \hat{n}_{eff} estimaatista.



Kuva 4.1: Esimerkin lineaarisen regression tulos, vasemmalla *Solar.R* -akselilla ja oikealla *Wind*. Punainen viiva on posteriori odotusarvolla piiretty regressioviiva ja vihreä on vertailun vuoksi PNS-mentelmällä sovitettu suora. Siniset ovat sovitteita parametrien eri ehdotus arvoilla.



Kuva 4.2: Esimerkin ketjut ja parametrien posteriori tiheydet

Luku 5

Loppusanat

Olemme nyt tarkastelleet perusajatuksia MCMC-menetelmistä. Kävimme läpi hieman teoriaa, esittelimme algoritmit ja kokeilimme sellaista käytännön tilanteessa. Kuitenkin olemme vain raapaisseet pintaa. Käyttämämme algoritmit ovat monessa mielessä erittäin rajoittuneita. Gibbsin otanta-algoritmissa meidän tulee tuntea marginaalijakaumat, ja Metropolis–Hastingsin algoritmissa voi olla välillä hidas konvergoitumaan.

Tärkeitä laajennuksia, jotka korjaavat edellisessä kappaleessa mainitsemani ongelmat, on myöhemmin kehitetyt tehokkaammat MCMC-metodit. Tärkeimpänä *Hamiltonian Monte Carlo* eli HMC. Se pyrkii vähentämään tarvittavien otosten määrää, joka tarvitaan tarpeeksi tarkan posterioriestimaatin saamiseksi, sillä menetelmä vähentää autokorrelaatiota tilojen välillä.

Ohitimme myös useita asioita liittyen Markovin ketjuihin. Markovin ketjujen matematiikka ei ole kovin vaikeaa käytännössä, mutta monet todistukset ovat työläisiä ja vaativat matematiikkaa, joka ylittää tämän tutkielman laajuuden.

Kuitenkin MCMC-menetelmät ovat mullistaneet maailmaa muunmuassa koneoppimis menetelmien massakaupallistumisen myötä. Ne ovat myös tehneet tieteestä luotettavampaa mahdollistamalla bayesiläisen tilastotieteen uuden nousun. Varsinkin replikaatiokriisin jälkeisessä maailmassa se on arvokas kontribuutio.

Paljon on kuitenkin vielä tutkittavaa. Suurista viimeaikaisista loikista huolimatta, MCMC-menetelmtä eivät voita vielääkään nopeudessa perinteisiä tilastollisia menetelmiä, joten uusia ja nopeampia algoritmeja olisi vielä kehiteltävä ja helppokäyttöisyyttä parannettava, jotta MCMC-menetelmät saavuttavat täyden potentiaalinsa.

Kirjallisuus

- [Dur10] Rick Durrett. *Probability: Theory and Examples*. 4. painos. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2010. DOI: 10.1017/CB09780511779398.
- [Gel92] Donald Rubin Gelman Andrew. “Inference from Iterative Simulation using Multiple Sequences”. *Statistical Science* 7 (1992), s. 457–511.
- [Gel98] Stephen Brooks Gelman Andrew. “General Methods for Monitoring Convergence of Iterative Simulations”. *Journal of Computational and Graphical Statistics* (joulukuu 1998). URL: <http://www.stat.columbia.edu/~gelman/research/published/brooksgelman2.pdf>.
- [Gey92] Charles Geyer. “Practical Markov Chain Monte Carlo”. *Statistical Science* 7.4 (1992), s. 473–483.
- [Kle13] A. Klenke. *Probability Theory: A Comprehensive Course*. Universitext. Springer London, 2013. ISBN: 9781447153603.
- [Koi09] Petri Koistinen. *Computational Statistics*. 2009.
- [Met53] Nicholas Metropolis. “Equation of state calculations by fast computing machines” (1953).
- [Pii] Petteri Piiroinen. *Stokastiset prosessit luentomoniste*.
- [RC05] Christian P. Robert ja George Casella. *Monte Carlo Statistical Methods (Springer Texts in Statistics)*. Berlin, Heidelberg: Springer-Verlag, 2005. ISBN: 0387212396.
- [Gel+13] Andrew Gelman et al. *Bayesian Data Analysis*. 3. painos. 2013. ISBN: 978-1-4398-4095-5.
- [Veh+19] Aki Vehtari et al. “Rank-normalization, folding, and localization: An improved \hat{R} for assessing convergence of MCMC”. *arXiv e-prints*, arXiv:1903.08008 (maaliskuu 2019), arXiv:1903.08008. arXiv: 1903.08008 [stat.CO].