

Gibbsin otanta- ja Metropolis-Hastingsin algoritmit

Topias Karjalainen

2. kesäkuuta 2020

Sisältö

1	Johdanto	2
2	Teoriaa	3
2.1	Perusmääritelmiä	3
2.2	Markovin ketjut	4
3	Markovin ketju Monte Carlo menetelmät	9
3.1	Gibbsin otanta-algoritmi	10
3.2	Metropolis–Hastings algoritmi	12
3.2.1	Yhteys Gibbsin otanta-algoritmiin	15
3.2.2	Ehdotusjakauman valinnasta	16
3.3	Yleisiä käytäntöjä MCMC-menetelmissä	17
3.4	Konvergenssi ja Diagnostiikka	17
3.4.1	Gelmanin \hat{R}	17
3.4.2	ESS	18
4	Laajempi esimerkki	20
5	Loppusanat	24

Luku 1

Johdanto

Tilastotieteissä *frekventistinen* koulukunta oli pitkään vallitseva koulukunta. Viimeaikoina kuitenkin suosiotaan on kasvattanut *bayesilainen* koulukunta. Aiemmin bayesiläinen päättely ei päässyt leviämään, sillä toisin kuin frekventistinen koulukunta, bayesilainen ajattelu ei tarjonnut suurinpaan osaan kysymyksiä analyttisiä ratkaisuja. Vasta tietokoneiden aikakautena *Markovin ketju Monte Carlo -menetelmät* (MCMC-menetelmät) ovat antaneet mahdollisuuden ratkaista epä-triviaaleja ongelmia bayesilaisessa kehyksessä.

Monte Carlo -menetelmän kehittäli 50-luvulla *Los Alamosissa* työskennelleet *Nicholas Metropolis*, *Stanislav Ulam* ja ehkä 1900-luvun merkityksellisin tiedemies *John von Neumann*. Yleinen määritelmä Monte Carlo -menetelmälle on toistuva satunnainen arvojen arpominen, aivan kuten *Monte Carlon* kasinopöydissä toistuvasti arvotaan satunnaisesti uusia arvoja korttipakasta, rulettipyörästä ja nopista. Nimensä menetelmä onkin saanut juuri tästä. Yksinkertainen esimerkki Monte Carlo simuloinnista on esimerkiksi π :n arvon estimointi arpomalla sattumanvaraisesti pisteitä tasosta, ja laskemalla kuinka moni niistä on ympyrän säteen sisällä.

Markovin ketjut taas ovat *stokastisia prosesseja*, jotka on nimetty venäläisen matemaatikon *Andrey Markovin* mukaan. Niitä karakterisoi *Markovin ominaisuus*, jota avataan kappaleessa 2.2.

Tässä tutkielmassa tulen ensin antamaan lyhyen johdatuksen Markovin ketjuihin ja selostan MCMC-menetelmien kannalta relevantin teorian. Tulen esittelemään lyhyesti kaksi algoritmia, joita käytetään MCMC-menetelmissä, *Gibbsin otanta-algoritmin* ja *Metropolis–Hastingsin algoritmin*. Esitän myös kaksi tärkeää diagnostiikkaa menetelmien tulosten arviointiin ja lopuksi vielä tarkastellaan käytännön esimerkkiä MCMC-algoritmista.

Luku 2

Teoriaa

2.1 Perusmääritelmiä

Määritellään ensiksi todennäköisyys. [Pii; Dur10]

Määritelmä 2.1. Olkoot Ω mielivaltainen epätyhjä joukko. σ -algebra perusjoukolla Ω on sen osajoukkojen joukkoperhe \mathcal{F} , joka toteuttaa ehdot:

1. $\emptyset \in \mathcal{F}$
2. jos $A \in \mathcal{F}$, niin $A^c \in \mathcal{F}$
3. jos $A_k \in \mathcal{F}$, kaikilla $k \in K$, missä K on numeroituva joukko, niin $\bigcup_{k \in K} A_k \in \mathcal{F}$

Määritelmä 2.2. Olkoot \mathcal{A} σ -algebra joukolla X . Pari (X, \mathcal{A}) on *mitallinen avaruus*.

Määritelmä 2.3. *Kolmogorovin aksioomat:* Olkoot (Ω, \mathcal{F}) mitallinen avaruus. Kuvaus \mathbf{P} liittää kuhunkin tapahtumaan A todennäköisyyden. Se on kuvaus $\mathbf{P} : \mathcal{F} \mapsto \mathbb{R}$ ja sille pätee:

1. $\mathbf{P}(A) \geq 0 \quad \forall A \in \mathcal{F}$
2. $\mathbf{P}(\Omega) = 1$
3. Jos $(A_k)_{k \in \mathbb{N}}$ ovat erillisiä tapahtumia, niin

$$\mathbf{P}\left(\bigcup_{k \in \mathbb{N}} A_k\right) = \sum_{k \in \mathbb{N}} \mathbf{P}(A_k)$$

Kuvausta \mathbf{P} kutsutaan *todennäköisyysmitaksi*.

Määritelmä 2.4. Kolmikkoa $(\Omega, \mathcal{F}, \mathbf{P})$ kutsutaan *todennäköisyysavaruudeksi*.

Määritelmä 2.5. *Satunnaismuuttuja* X on (lähes) mielivaltainen kuvaus $X : \Omega \rightarrow S$, jossa S on tilajoukko.

2.2 Markovin ketjut

Esitellään ensiksi joitain perusasioita Markovin ketjuista, sillä ne eivät kuulu sellaisenaan opetussuunnitelmaan. Aloitetaan määrittelemällä stokastinen prosessi.[Pii]

Määritelmä 2.6. Jono $(X_n : n = 1, 2, 3, \dots)$ satunnaismuuttujia on diskreettiaikainen *stokastinen prosessi*.

Merkintä 2.7. Merkitään stokastista prosessia merkinnällä (X_n)

Esitetään nyt *Markovin ehto* diskreetille tilajoukolle määritelmässä 2.11, ja laajennetaan se jatkuvalle tilajoukolle määritelmässä 2.14. [RC05] Määritellään kuitenkin ensin siirtymäydin, eli jakauma, joka määrittelee tilojen välisten siirtymien todennäköisyydet. [Kle13, s. 180]

Määritelmä 2.8. Olkoot (S, \mathcal{S}) ja (Y, \mathcal{Y}) mitallisia avaruuksia. *Siirtymäydin* on funktio $T : S \times \mathcal{Y} \rightarrow [0, \infty[$, jolle pätee

(i) $\forall s \in S : A \mapsto T(s, A)$ on todennäköisyyksimitta

(ii) $\forall A \in \mathcal{Y} : s \mapsto T(s, A)$ on mitallinen

Diskreetissä tapauksessa siirtymäydinä kutsutaan *siirtymämatriisiksi*, joka on

$$(2.9) \quad p_{ij} = \mathbf{P}(X_n = i | X_{n-1} = j), \quad \forall i, j \in S$$

Jatkuvassa tapauksessa ydin kuvaa ehdollista todennäköisyyttä $P(X_{n+1} \in A | X_n = x) = \int_A T(x, x') dx'$. Tälle pätee, että

$$(2.10) \quad \int_S T(x, x') dx' = 1$$

Määritelmä 2.11. Stokastinen prosessi (X_n) on *Markovin ketju* diskreetissä tilajoukossa, jos kaikilla alkuhetkillä m, n ja tiloilla $i, j \in S$ on voimassa

$$(2.12) \quad \begin{aligned} & \mathbf{P}(X_{n+1} = j | X_0 = i_0, X_1 = i_1, \dots, X_{n-1} = i_{n-1}, X_n = i) \\ &= \mathbf{P}(X_{n+1} = j | X_n = i) \end{aligned}$$

ja *siirtymätodennäköisyyksille* on voimassa

$$(2.13) \quad p_{ij} = \mathbf{P}(X_{n+1} = j | X_n = i) = \mathbf{P}(X_{m+1} = j | X_m = i)$$

Yhtälöä 2.12 kutsutaan *Markovin-ehdoksi* ja yhtälöä 2.13 taas kutsutaan *stationarisuusehdoksi*, mikä tarkoittaa, että siirtymätodennäköisyys tilojen i ja j välillä ei riipu ajasta m ja n , vaan pelkästään tiloista i ja j .

Määritelmä 2.14. Stokastinen prosessi (X_n) on *Markovin ketju* jatkuvassa tilajoukossa, jos kaikilla alkuhetkillä n , X_n :n ehdolliselle jakaumalle pätee

$$(2.15) \quad \mathbf{P}(X_{n+1} \in A | X_n = x_n, \dots, X_0 = x_0) = \mathbf{P}(X_{n+1} \in A | X_n = x_n)$$

Määritelmä 2.16. Satunnaismuuttujan X_0 jakaumaa kutsutaan *alkujakaumaksi*.

MCMC-menetelmien kannalta keskeinen ominaisuus Markovin ketjulle on sen tasapainojakauma (eng. *invariant distribution*). Siihen perustuu idea ko. menetelmän takana. Esitetään seuraavaksi tämä ominaisuus, sekä määritellään toinen ominaisuus, *kääntävä Markovin ketju*, esittämällä ns. *detailed balance*-yhtälö, jota tarvitaan Metropolis-Hastingsin -algoritmin tasapainojakauman olemassaolon osoittamiseen.

Määritelmä 2.17. Todennäköisyysjakauma $\pi = (\pi_i)_{i \in S}$ on diskreetin tilajoukon Markovin ketjun (X_n) tasapainojakauma, jos

$$(2.18) \quad \sum_{i \in S} \pi_i p_{ij} = \pi_j, \forall j \in S$$

Yhtälö 2.18 voidaan kirjoittaa myös muotoon

$$(2.19) \quad \pi^T \mathbf{P} = \pi^T$$

Jakauma π on jatkuvan tilajoukon Markovin ketjun (X_n) tasapainojakauma jos

$$(2.20) \quad \pi(y) = \int_S \pi(x) T(x, y) dx$$

Määritelmä 2.21. Markovin ketju on *kääntävä*, jos löytyy sellainen todennäköisyysjakauma $\lambda = (\lambda_i)_{i \in S}$, että

$$(2.22) \quad \lambda_i p_{ij} = \lambda_j p_{ji}, \forall i, j \in S$$

Määritelmä 2.23. Markovin ketju jatkuvassa tilajoukossa S on kääntävä, jos on olemassa sellainen todennäköisyys tiheys $\pi(x)$ joukossa S , että

$$(2.24) \quad \pi(x) T(x, y) = \pi(y) T(y, x), \forall x, y \in S$$

Kääntävällä Markovin ketjulla on sellainen mukava ominaisuus, että ketjun kääntyvyys on riittävä ehto tasapainojakauman olemassa ololle. Osoitamme tämän seuraavaksi.

Lause 2.25. Jos Markovin ketju on kääntävä, niin $\lambda = \pi$ on sen tasapainojakauma.

Todistus.

$$\sum_{i \in S} \lambda_i p_{ij} = \sum_{i \in S} \lambda_j p_{ji} = \lambda_j \sum_{i \in S} p_{ij} = \lambda_j$$

□

Lause 2.26. Jos Markovin ketju (X_n) on kääntyvä ja tilajoukko S on jatkuva, niin π on sen tasapainojakauma.

Todistus. Yhtälön 2.10 mukaan $\int_S T(y, x) dx = 1$, joten


$$(2.27) \quad \int_S \pi(x) T(x, y) dx = \int_S \pi(y) T(y, x) dx = \pi(y) \int_S T(y, x) dx = \pi(y)$$

□

Esimerkki 2.28. Pohditaan lyhyttä esimerkkiä, jossa tilajoukko on $S = \{”sataa”, ”paistaa”\}$. Määritellään siirtymätodennäköisyydet siirtymämatriisilla

$$\mathbf{P}^{(1)} = \begin{pmatrix} 0.7 & 0.3 \\ 0.2 & 0.8 \end{pmatrix}$$

Tämä voidaan visualisoida kuvan 2.28 mukaisesti. Yhtälö 2.19 implikoi, että jakauma π



Kuva 2.1: Esimerkki 2.28

on siirtymämatriisin \mathbf{P} vasen ominaisvektori ($\pi^T \mathbf{P} = \lambda \pi^T$, jossa $\lambda = 1$). Tämä voidaan ratkaista numeerisesti, ja ratkaisu on $\pi^T = (0.4, 0.6)$. Helposti nyt nähdään, että 2.19 pätee.

Seuraavaksi esitellään lyhyeksi *syklinen siirtymäydin*, ja osoitetaan tulos, jota tarvitsemme Gibbsin otanta-algoritmin tasapainojakauman todistuksen yhteydessä.

Määritelmä 2.29. Markovin ketjuissa voimme myös tietyin ehdoin yhdistää siirtymätiheyksiä. Tällöin puhutaan syklisistä siirtymätiheyksistä. Diskreetissä tilanteessa siirtymätodennäköisyys

$$(2.30) \quad T_1 \dots T_d(x, y)$$

voidaan määritellä matriisitulona $P_1 P_2 \dots P_d$. Jatkuvassa tapauksessa taas määritellään, että $T_c = T_1 \dots T_d(x, y)$ on syklinen, jos

$$(2.31) \quad T_c(x, y) = \int_S T_1(x, z_1) T_2(z_1, z_2) \dots T_d(z_{d-1}, y) dz_1 \dots z_{d-1}$$

Lause 2.32. Jos tilajoukko S on diskreetti ja π^T on tasapainojakauma kaikille siirtymämatriiseille P_1, \dots, P_d , niin se on tasapainojakauma siirtymämatriisille $P = P_1 \dots P_d$.

Todistus.

$$\pi^T P = \pi^T P_1 \dots P_d = \pi^T P_2 \dots P_d = \dots = \pi^T P_d = \pi^T$$

□

Lause 2.33. Jos tilajoukko S on jatkuva ja π on tasapainojakauma kaikille siirtymätiheyksille T_1, \dots, T_d , niin se on tasapainojakauma siirtymätiheydelle $T_c = T_1 \dots T_d(x, y)$

Todistus. Lause voidaan todistaa hyödyntämällä Fubinin lausetta.

$$(2.34) \quad \begin{aligned} \int_S \pi(x) T_c(x, y) dx &= \int_S \pi(x) \int_S T_1(x, z_1) T_2(z_1, z_2) \dots T_d(z_{d-1}, y) dz_1 \dots z_{d-1} dx \\ &= \int_S T_2(z_1, z_2) \dots T_d(z_{d-1}, y) \underbrace{\int_S \pi(x) T_1(x, z_1) dx}_{\pi(z_1)} dz_1 \dots z_{d-1} \\ &= \int_S T_3(z_2, z_3) \dots T_d(z_{d-1}, y) \underbrace{\int_S \pi(z_1) T_2(z_1, z_2) dz_1}_{\pi(z_2)} dz_2 \dots z_{d-1} \\ &\vdots \\ &= \int_S \pi(z_{d-1}) T_d(z_{d-1}, y) dz_{d-1} \\ &= \pi(y) \end{aligned}$$

Tässä S viittaa nyt aina siihen tilajoukkoon, jonka yli kussakin vaiheessa integroidaan.

□

Käydään vielä nopeasti läpi muutama ominaisuus, jotka ovat keskeisiä MCMC-menetelmien teoriassa. [RC05; Koi09]

Määritelmä 2.35. Markovin ketju (X_n) , siirtymäytimellä $T(x, y)$ on *pelkistymätön* jos kaikilla $A \in \mathcal{T}$, joilla $P(A) > 0$, on olemassa sellainen n , että $T^n(x, A) > 0$ kaikilla $x \in S$

Käytännössä pelkistymättömyys tarkoittaa siis sitä, että jokaisesta tilajoukon kolkasta on mahdollista päästä jokaiseen muuhun pisteeseen avaruutta, eli ketju ei voi jäädä jumiin johonkin alueelle.

Määritelmä 2.36. Markovin ketju (X_n) on *palautuva* jos

- (i) ketju (X_n) on pelkistymätön ja
- (ii) kaikilla $A \in \mathcal{T}$, joilla $\mathbf{P}(A) > 0$, $\mathbb{E}_x[\eta_A] = \infty$ kaikilla $x \in A$

Missä η_A on käyntien määrä joukossa A .

Palautuvalla ketju tarkoittaa sitä, että ketju palaa alueelle, jossa se on jo käynyt. Palautumista vahvempi ominaisuus on *Harris-palautuvuus*.

Määritelmä 2.37. Joukko A on Harris palautuva, jos $\mathbf{P}_x(\eta_A = \infty) = 1$ kaikilla $x \in A$. Markovin ketju (X_n) on Harris palautuva jos (X_n) on pelkistymätön, ja jokainen joukko A , jolla $\mathbf{P}(A) > 0$, on Harris palautuva.

Määritelmä 2.38. Markovin ketju (X_n) on *jaksollinen*, jos on olemassa erilliset osajoukot $A_1, A_2, \dots, A_d \subset S, d > 1$, että

$$(2.39) \quad T(x, A_{i+1}) = 1, \quad \forall x \in A_i, \quad i = 1, \dots, d-1$$

ja

$$(2.40) \quad T(x, A_1) = 1, \quad x \in A_d$$

Jos ketju ei ole jaksollinen, se on *jaksoton*.

Määritellään sitten vielä *ergodisuus*, joka yhdistää yllä olevat ominaisuudet.

Määritelmä 2.41. Markovin ketju (X_n) on ergodinen, jos se on pelkistymätön, jaksoton ja Harris-palautuva.

Ergodisuus on MCMC-menetelmien kannalta tärkeä ominaisuus, sillä se takaa Markovin ketjun (X_n) konvergoitumisen yksikäsitteisen tasapainojakaumaansa mistä tahansa tilajoukon S pisteestä. Tämän osoittaminen on melko hankalaa ja ylittää reilusti tämän tutkielman laajuuden, joten jätämme sen tekemättä.

Luku 3

Markovin ketju Monte Carlo menetelmät

Tässä luvussa aiomme esitellä MCMC-metodeja. Esittelemme alaluvussa 3.6 Gibbsin otanta-algoritmina tunnetun MCMC-menetelmän, ja sitten alaluvussa 3.2 esittelemme Metropolis–Hastings algoritmin. Osoitamme myös, että todellisuudessa alaluvun 3.6 algoritmi onkin todella vain erikoistapaus luvun 3.2 algoritmista. Pohditaan kuitenkin ensin menetelmän motivaatiota. [Koi09, s. 94] [RC05, s. 269]

Määritelmä 3.1. MCMC-menetelmiksi kutsutaan jakaumaa p simuloivia menetelmiä, jotka perustuvat siihen, että luodaan ergodinen Markovin ketju (X_n) , jolla on tasapainojakaumana jakauma p .

Ketjun ergodisuus takaa siis sen, että ketju konvergoituu jokaisesta tila-avaruuden pisteestä. Se takaa, että ketjun empiirinen keskiarvo

$$(3.2) \quad \mathfrak{J}_n = \frac{1}{n} \sum_{t=1}^n h(X_t)$$

konvergoituu odotusarvoon, eli

$$(3.3) \quad \lim_{n \rightarrow \infty} \mathfrak{J}_n \rightarrow \mathbb{E}_p[h(X_t)] = \int h(x)p(x)dx$$

Tällöin ketjun tiloja voidaan siis käsitellä i.i.d. otoksena tasapainojakaumasta.

Markovin ketjuille (ja useimmille MCMC-menetelmien tuottamille Markovin ketjuille) pätee myös keskeinen raja-arvolause (3.4).

$$(3.4) \quad \sqrt{n}(\mathfrak{J}_n - \mathbb{E}_p[h(X_t)]) \rightarrow N(0, \sigma_h^2) \quad \text{kun } n \rightarrow \infty$$

jossa

$$(3.5) \quad \sigma_h^2 = \text{var}_p(h(X_0)) + 2 \sum_{t=1}^{\infty} \text{cov}_p(h(X_0), h(X_t))$$

Menetelmän ydin on siis rakentaa systemaattisella tavalla Markovin ketju, jonka tasapainojakaumana on haluamamme simuloitava jakauma. Tämän voisi kuvitella olevan kovin vaikeaa, mutta yllättävästi se onkin melko helppoa.

3.1 Gibbsin otanta-algoritmi

Gibbsin otanta-algoritmi on tapa simuloida bayesiläistä moniulotteista posteriorijakautta (eli ulottuvuuksia vähintään 2), kun suora otanta on hankalaa. Algoritmi on nimetty amerikkalaisen fyysikon, *Josiah Willard Gibbsin* (1839-1903) mukaan, mutta sen todellinen kehittäjä on veljekset *Donald Geman* (1943-) ja *Stuart Geman* (1949-) vuonna 1984 artikkelissa *Stochastic Relaxation, Gibbs Distributions, and the Bayesian Restoration of Images*.

Aloitetaan määrittelemällä algoritmi. [Gel+13, s.276-277]

Määritelmä 3.6. Olkoot θ parametrivektori, joka jaetaan d :hen osaan tai osavektoriin, eli $\theta = (\theta_1, \theta_2, \dots, \theta_d)$. Gibbsin otanta-algoritmi määritellään seuraavanlaisesti:

1. Arvotaan permutaatio parametrivektorille θ
2. Arvotaan uusi tila jokaiselle osavektorille θ_j ehdollistamalla se jokaiselle muulle parametrille, eli vedetään arvot $\theta_1, \theta_2, \dots, \theta_d$ jakaumista

$$(3.7) \quad p(\theta_j | \theta_{-j}^{(n-1)}, y)$$

arvotun permutaation parametrijärjestyksessä

3. toistetaan 1-3

Huomautus 3.8. jakaumassa (3.7) merkintä $\theta_{-j}^{(n-1)}$ viittaa kaikkiin muihin parametrin θ komponentteihin paitsi j . komponenttiin, näiden tämänhetkisillä arvoilla eli

$$\theta_{-j}^{(n-1)} = (\theta_1^{(n-1)}, \dots, \theta_{j-1}^{(n-1)}, \theta_{j+1}^{(n-1)}, \dots, \theta_d^{(n-1)})$$

Yleensä määritelmässä 3.6 kohdassa 1. ei arvota uutta permutaatiota, vaan permutaatio päätetään alussa, ja sitä pidetään kaikkien algoritmien iteraatioiden ajan samana. Tätä kutsutaan *systemaattiseksi Gibbsin otanta-algoritmiksi* (*systematic scan Gibbs sampler*).

Lause 3.9. *Määritelmän 3.6 mukaisen algoritmin tuottama Markovin ketju on jaksoton, pelkistymätön ja Harris palautuva ja sillä on sitten yksikäsitteinen tasapainojakauma $p(\theta)$. [Koi09]*

Todistus. Voitaisiin osoittaa, että määritelmän 3.6 algoritmin tuottama Markovin ketju on ergodinen, ja täten konvergoituu tasapainojakaumaan. Ohitetaan se tässä, sillä todistus on melko tekninen.

Olkoot $\theta^{(n-1)}$ parametrin alkuperäinen tila, ja $\theta_j^{(n)}$ uusi j :nnen parametrin tila. Nyt $\theta^{(n-1)}$ ja $\theta_j^{(n)}$ yhteistiheysfunktio on kertolaskusäännöllä.

$$(3.10) \quad p(\theta^{(n-1)}) p_j(\theta_j^{(n)} | \theta_{-j}^{(n-1)})$$

Nyt voidaan integroida

$$\begin{aligned}
(3.11) \quad \int p(\theta^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} &= \int p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} \\
&= p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)}) \int p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})d\theta_j^{(n-1)} \\
&= p(\theta_{-j}^{(n-1)})p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)}) \\
&= p(\theta_j^{(n)}, \theta_{-j}^{(n-1)})
\end{aligned}$$

Eli Gibbs otanta-algoritmin päivitys ei muuta jakaumaa. Nyt voidaan soveltaa lausetta 2.33, jolloin voidaan todeta, että koska p tasapainojakauma jokaiselle $p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})$, niin se on tasapainojakauma niiden yhteis siirtymätiheydelle

$$(3.12) \quad T = \prod_{j=1}^d p_j(\theta_j^{(n)}|\theta_{-j}^{(n-1)})$$

□

Ohitetaan Gibbsin otanta-algoritmin kohdalla toistaiseksi esimerkit, ja palataan siihen kappaleessa 4, jossa tarkastelemme laajempaa esimerkkiä lineaarisen regression parissa. Toteutamme tämän Gibbsin otanta-algoritmina.

Gibbsin otanta-algoritmin vaatimus ehdollisista jakaumista voi vaikuttaa jokseenkin rajoittavalta, sillä joskus voidaan tutkia mallia, jolle on vaikea laskea ehdolliset jakaumat. Toisaalta taas joskus saatamme haluta simuloida yksiulotteista jakaumaa Gibbsin otanta-algoritmillä, mutta tämä ei suoraan ole mahdollista sillä algoritmi tarvitsee vähintään kaksiulotteisen parametrin. Tällöin voidaan kuitenkin pienin muunnoksia hyödyntää Gibbsin otanta-algoritmia hyödyntämällä seuraavaa määritelmää 3.13. [RC05, s. 374]

Määritelmä 3.13. Olkoot p tiheysfunktio. Tiheysfunktioita λ , joka täyttää ehdon

$$(3.14) \quad \int_Z \lambda(x, z)dz = p(x)$$

kutsutaan p :n täydellistymäksi (*completion*).

Tiheys λ valitaan siten, että sille voi ratkaista ehdolliset jakaumat. Nyt Gibbsin otanta-algoritmi voidaan toteuttaa käyttämällä jakaumaa λ ja sen ehdollisia jakaumia. Lauseen 3.9 tulos pätee myös tässä tapauksessa. Tällöin malliin tulee toki uusi parametri z , joka on täysin turha mallin kannalta, mutta avustaa simuloinnissa.

3.2 Metropolis–Hastings algoritmi

Metropolis–Hastings algoritmi on kehittelijöidensä *Nicholas Metropolin* (1915-1999) ja *Wilfred Keith Hastingsin* (1930-2016) mukaan nimetty MCMC-menetelmä, jolla voidaan simuloida bayesiläisessä analyysissä käytettäviä posteriori jakaumia myös silloin kun tiheys on mahdotonta määrittää analyttisesti.

Algoritmin pohjan kehittivät *Stanislav Ulam* ja Metropolis työskennellessään *Los Alamosissa* ja myöhemmin Metropolis kehitti nykyään *Metropolis-algoritmina* tunnettua algoritmia ja esittelivät sen artikkelissa *Equation of state calculations by fast computing machines* [Met53]. Tämä versio algoritmista vaati, että pian esiteltävä *ehdotusjakauma* on symmetrinen. Myöhemmin *Hastings* laajensi algoritmin koskemaan myös epäsymmetrisiä ehdotusjakaumia artikkelissa *Monte Carlo Sampling Methods Using Markov Chains and Their Applications*. Esitämme jälkimmäisen version algoritmista, sillä edellinen seuraa jälkimmäisestä suoraan.

Merkintä 3.15. TN-jakauma $J_n(\cdot|\cdot)$ on niin sanottu *ehdotusjakauma* (*proposal distribution*, *jumping distribution*), josta *MH-algoritmista* arvotaan ehdotustila.

Nyt kun ehdotusjakauma on määritelty, voidaan määritellä Metropolis-Hastingsin algoritmi seuraavanlaisesti [Gel+13, s.278-279]

Määritelmä 3.16. Metropolis–Hastings algoritmi on seuraavanlainen

1. Valitaan aloitustila θ_0 tilajoukosta (tämän askeleen aika on $n = 0$)
2. Generoidaan kandidaatti tila θ' satunnaisesti ehdotusjakaumasta $J_n(\theta'|\theta^{(n-1)})$
3. Lasketaan suhde

$$r = \frac{p(\theta'|y)/J_n(\theta'|\theta^{(n-1)})}{p(\theta^{(n-1)}|y)/J_n(\theta^{(n-1)}|\theta')}$$

4. Asetetaan

$$\theta^{(n)} = \begin{cases} \theta', & \text{todennäköisyydellä } \min(r, 1) \\ \theta^{(n-1)}, & \text{muuten} \end{cases}$$

5. Toistetaan 2-5

Lause 3.17. Määritelmän 3.16 algoritmi tuottaa Markovin ketjun jolla on uniikki tasapainojakauma $p(\theta)$

Todistus. Todistus nojautuu Markovin ketjun kääntyvyysominaisuuteen (2.21) ja (2.23), eli

$$(3.18) \quad T(\theta^{(n)}|\theta^{(n-1)})p(\theta^{(n-1)}) = T(\theta^{(n-1)}|\theta^{(n)})p(\theta^{(n)})$$

joka on siis riittävä ehto tasapainojakauman olemassaololle. Mietitään kahta tapausta: (1) $\theta^{(n)} \neq \theta^{(n-1)}$ ja (2) $\theta^{(n)} = \theta^{(n-1)}$. Tapauksen (2) siirtymä voi tapahtua kahdella tavalla. Josko kohdassa 4. ehdotus θ' hylätään, tai se hyväksytään, mutta osutaan sattumanvaraisesti takaisin samaan kohtaan. Kuitenkin selvästi nähdään, että ehto 3.18 pätee tilanteessa (2).

Tilanteessa (1) siirtymätodennäköisyys pisteestä $\theta^{(n-1)}$ pisteeseen $\theta^{(n)}$ on

$$(3.19) \quad T(\theta^{(n)}|\theta^{(n-1)}) = J_n(\theta^{(n)}|\theta^{(n-1)}) \min \left(\frac{p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)})}{p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)})}, 1 \right)$$

Jota voidaan muokata helposti muotoon

$$(3.20) \quad \begin{aligned} T(\theta^{(n)}|\theta^{(n-1)}) &= J_n(\theta^{(n)}|\theta^{(n-1)}) \min \left(\frac{p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)})}{p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)})}, 1 \right) \\ &= \frac{1}{p(\theta^{(n-1)})} \min \left(p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}), p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}) \right) \end{aligned}$$

Toistamalla ylläoleva siirtymätodennäköisyydelle pisteestä $\theta^{(n)}$ pisteeseen $\theta^{(n-1)}$ havaitaan, että

$$(3.21) \quad T(\theta^{(n-1)}|\theta^{(n)}) = \frac{1}{p(\theta^{(n)})} \min \left(p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}), p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}) \right)$$

lauseke on symmetrinen. Kerrotaan yhtälö (3.20) termillä $p(\theta^{(n-1)})$ ja hyödynnetään ominaisuutta (3.21), jolloin

$$\begin{aligned} T(\theta^{(n)}|\theta^{(n-1)})p(\theta^{(n-1)}) &= \frac{1}{p(\theta^{(n-1)})} \min \left(p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}), p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}) \right) p(\theta^{(n-1)}) \\ &= \frac{1}{p(\theta^{(n)})} \min \left(p(\theta^{(n-1)})J_n(\theta^{(n)}|\theta^{(n-1)}), p(\theta^{(n)})J_n(\theta^{(n-1)}|\theta^{(n)}) \right) p(\theta^{(n)}) \\ &= T(\theta^{(n-1)}|\theta^{(n)})p(\theta^{(n)}) \end{aligned}$$

Eli myös tapauksessa (1) yhtälö (3.18) pätee. □


Esimerkki 3.22. Ajatellaan kuvitteellista tapausta, jossa meillä jatkuva kaksiulotteinen todennäköisyysjakauma, jonka tiheysfunktio on

$$(3.23) \quad p(\theta) \propto \exp(-5|\theta_1^2 + \theta_2^2 - 1|)$$

joka muodostaa regasmaisen 2-ulotteisen jakauman. Valitaan ehdotusjakaumaksi $J_n(\theta^{(n)}|\theta^{(n-1)})$ 2d-multinormaalijakauma

$$(3.24) \quad J_n(\theta^{(n)}|\theta^{(n-1)}) \sim N(\theta^{(n-1)}, \sigma^2 I_2)$$

jossa I_2 on 2×2 yksikkömatriisi ja olkoot $\sigma^2 = 0.01$. Nyt Metropolis-Hastingsin algoritmin avulla voidaan simuloida jakaumaa $p(\theta)$ algoritmilla 3.16. Simuloidaan kaksi Markovin ketjua asettamalla aloitustiloiksi $(0, 0)$ ja $(5, 5)$, kummastakin 10 000 tilaa. Simuloimme



Kuva 3.1: Vasemmalla: $(5,5)$. Keskellä: $(0,0)$ Oikealla: tiheystestimaatti (huomaa eri skaalaa).

myös 200 000 pistettä aloitusarvolla $(0,0)$, joista luodaan tiheystestimaatti. Tulokset löytyy kuvasta 4.2. Kahdessa ensimmäisessä kuvassa viiva on ensimmäisen 250 pisteen polku. Selvästi nähdään, että aloituspisteellä ei ole väliä. Markovin ketjun tasapainojakauma on sama huolimatta aloituspisteestä.


Esimerkki 3.25. Otetaan toisena esimerkkinä klassinen tapaus, jossa oletetaan, että havainnot ovat jakautuneet *Bernoulli-jakauman* mukaan, $y_i \sim \text{Bernoulli}(\theta)$, ja että prior on tasajakauma. Tällöin tiedetään, että analyyttinen posteriori on

$$p(\theta|y_i) = \text{Beta}\left(\sum_{i=1}^n y_i + 1, n - \sum_{i=1}^n y_i + 1\right)$$

Valitaan hieman eksoottinen ehdotusjakauma esimerkin vuoksi:

$$(3.26) \quad J_n(\theta^{(n)}|\theta^{(n-1)}) \sim \begin{cases} \text{Unif}(\theta^{(n-1)}, 1) & \text{kun } \theta^{(n-1)} < 0.5 \\ \text{Unif}(0, \theta^{(n-1)}) & \text{kun } \theta^{(n-1)} \geq 0.5 \end{cases}$$

Toisin kuin esimerkissä 3.22, nyt ehdotusjakauma ei olekkaan symmetrinen.



Kuva 3.2: Esimerkin 3.25 tulokset

Oletetaan että, meillä on havainnot $(1, 1, 1, 0, 0, 1, 0, 0, 0, 0)$ ja tarkastellaan sekä analyttistä että MH-algoritmin tuottamaa jakaumaa ja niiden eroja.

Kuvasta 3.2 nähdään esimerkin tulokset. Huomataan, että vaikka ehdotusjakauma on melko kummallinen, niin kuitenkin riittävän monella iteraatiolla saavutetaan tasapainojakauma. Huomaa, että vasemmassa kuvaajassa on vihreällä simulaatio keskiarvo, ja punaisella analyttinen keskiarvo, mutta nämä arvot ovat niin lähellä toisiaan, että viivat ovat päällekkäin.

3.2.1 Yhteys Gibbsin otanta-algoritmiin

Kuten jo totesimme aiemmin, Gibbsin otanta-algoritmin voi esittää Metropolis-Hastings algoritmin erityis tilanteena, jossa hyväksymistodennäköisyys on 1. [Gel+13]

Lause 3.27. *Gibbsin otanta-algoritmi on erityistapaus Metropolis-hastings algoritmista.*

Todistus. Määritellään MH-algoritmin iteraatio n niin, että se sisältää d askelta, ja jossa iteraation n askel j kuvaa parametriosavektorin θ_j päivitystä ehdollistettuna kaikilla muilla parametrin θ :n elementeillä. Tällöin ehdotusjakauma $J_{j,n}$ iteraation n askeleessa j , voidaan määrittää siten, että se ehdottaa vain tiloja, jotka muuttaa vain parametria θ_j . Eli:

$$(3.28) \quad J_{j,n}^{Gibbs}(\theta^* | \theta^{(n-1)}) = \begin{cases} p(\theta_j^* | \theta_{-j}^{(n-1)}) & \text{kun } \theta_{-j}^* = \theta_{-j}^{(n-1)} \\ 0 & \text{muulloin} \end{cases}$$

Nyt voidaan kirjoittaa suhde r iteraation n j :nen askeleen kohdalla muotoon

$$\begin{aligned}
 r &= \frac{p(\theta^*)/J_{j,n}^{Gibbs}(\theta^*|\theta^{(n-1)})}{p(\theta^{(n-1)})/J_{j,n}^{Gibbs}(\theta^{(n-1)}|\theta^*)} \\
 &= \frac{p(\theta^*)/p(\theta_j^*|\theta_{-j}^{(n-1)})}{p(\theta^{(n-1)})/p(\theta_j^{(n-1)}|\theta_{-j}^{(n-1)})} \\
 (3.29) \quad &= \frac{p(\theta_{-j}^{(n-1)})}{p(\theta_{-j}^{(n-1)})} \\
 &= 1
 \end{aligned}$$

Eli määrittelemällä MH-algoritmille siirtymäjakauma sillä tavalla, että se vastaa Gibbsin otanta-algoritmia, siirtymän hyväksymistodennäköisyydeksi tulee 1. □

3.2.2 Ehdotusjakauman valinnasta

Kummassakin kappaleen 3.2 esimerkissä valitsimme ehdotusjakauman melko satunnaisesti. Varsinkin esimerkissä 3.25 se on erittäin epätavallinen, mistä syystä hyvän approksimaation saavuttaminen vie todella monta iteraatiota. Yleensä jos haluamme oikeasti tehokkaasti ja ekonomisesti simuloida jakaumia esitetyllä algoritmilla, haluamme valita ehdotusjakauman jollakin järkevällä, systemaattisella tavalla, joka minimoisi tarvittavien iteraatioiden määrän.

Yleisesti ottaen hyvällä ehdotusjakaumalla on muutama ominaisuus[Gel+13, s. 280]

1. Kaikilla θ :n arvoilla on helppo arpoa arvo $J(\theta'|\theta)$
2. Suhde r on helppo laskea
3. Siirtymät ovat tarpeaksi pitkiä. Muuten Markovin ketju etenee liian hitaasti ja hyvän estimaatin saaminen kestää liian pitkään.
4. Siirtymiä ei hylätä liian usein. Muuten Markovin ketju ei etene vaan seisoo paikallaan.

Lisäksi simulointia voidaan nopeuttaa mm. käyttämällä adaptiivista ehdotusjakaumaa, j ehdotusjakaumaa muunnellaan riippuen ketjun liikkeistä. [Gel+13, s. 295]

3.3 Yleisiä käytäntöjä MCMC-menetelmissä

Usein on tapana simuloida useampi kuin yksi ketju kustakin tapauksesta. Tällöin asetetaan näiden ketjujen aloitustilat eriäviksi, jotta saadaan vähennettyä aloitustilan vaikutusta lopputulokseen.

Toinen yleinen käytäntö on jättää ketjun alkupäästä jonkin verran tiloja huomiotta, sillä ketjun alkupäässä ei se ei välttämättä ole vielä saavuttanut tasapainojakaumaa. Tätä kutsutaan *Burn-in periodiksi*.

Joskus taas on hyvä tapa pudottaa joka n :s tila ketjusta. Tilojen tiputtaminen ei vaikuta tasapainojakaumaan, kunhan ketju vain on saavuttanut sen. Tilojen tiputtamista on hyötyä jos mallissa on paljon parametreja, jolloin tietokoneessa voi tulla ongelmia tilan kanssa.

3.4 Konvergenssi ja Diagnostiikka

Kappaleissa 3.6 ja 3.2 esiteltyjen algoritmien kohdalla voi herätä kysymys, että mikä on riittävä määrä iteraatioita, jotta Markovin ketju on saavuttanut tasapainojakaumansa ja otanta on riittävän hyvä aproksimaatio posteriorijakaumasta. Esimerkiksi kun katsotaan kuvan 4.2 vasemman puolen kuvan punaista polkua, niin voidaan sanoa, että se ei ole vielä saavuttanut tasapainojakaumaa sillä haluttu jakauma tunnetaan, mutta tätä ei välttämättä osata sanoa suoraan.

Toinen yleinen ongelma, joka kaipa pohdintaa on se, että ketjujen sisällä on korrelaatiota, mikä vaikeuttaa päättelyä simuloinnin tuloksista. Otannat eivät siis ole välttämättä täysin riippumattomia.

3.4.1 Gelmanin \hat{R}

Yksi yleisimmistä estimaattoreista, joita käytetään MCMC-metodeissa Markovin ketjujen konvergenssin arvioimiseen on *Andrew Gelmanin* \hat{R} . Se mittaa ketjujen sisäistä sekoittumista (eng. *mixing*) ja erillisten ketjujen välistä sekoittumista.[Gel92; Gel98]

Määritelmä 3.30. *Gelmanin* \hat{R} lasketaan jakamalla ensin jokin määrä simuloituja ketjua erillisillä aloituspisteillä keskeltä kahtia. Olkoon nyt m ketjujen määrä jaon jälkeen ja n ketjujen pituus. Olkoot $\psi_{ij}(i = 1, \dots, n; j = 1, \dots, m)$ tila i ketjussa j . Nyt merkitään

$$(3.31a) \quad B = \frac{n}{m-1} \sum_{j=1}^m (\bar{\psi}_{\cdot j} - \bar{\psi}_{\cdot \cdot})^2, \quad \text{jossa}$$

$$(3.31b) \quad \bar{\psi}_{.j} = \frac{1}{n} \sum_{i=1}^n \psi_{ij}$$

$$(3.31c) \quad \bar{\psi}_{..} = \frac{1}{m} \sum_{j=1}^m \bar{\psi}_{.j}$$

Ja merkitään

$$(3.32) \quad W = \frac{1}{m} \sum_{j=1}^m s_j^2, \text{ jossa } s_j^2 = \frac{1}{n-1} \sum_{i=1}^n (\psi_{ij} - \bar{\psi}_{.j})^2$$

Jossa siis B on ketjujen välinen varianssi (*between sequence*) ja W on ketjujen sisäinen varianssi (*within sequence*). Näiden painotettuna keskiarvona saadaan estimaattori parametrin ψ marginaaliselle posteriorivarianssille

$$(3.33) \quad \hat{\sigma}^+(\psi|y) = \frac{n-1}{n}W + \frac{1}{n}B$$

Nyt \hat{R} voidaan määritellä

$$(3.34) \quad \hat{R} = \sqrt{\frac{\hat{\sigma}^+(\psi|y)}{W}}$$

Gelmanin \hat{R} mittaa sitä miten paljon kullakin hetkellä ψ :n jakauma voisi supistua, jos simulaatioiden annettaisiin jatkua loputtomasti. Eli siis kun $\hat{R} \approx 1$, niin voidaan sanoa, että Markovin ketju on todennäköisesti saavuttanut tasapainojakaumansa, sillä tällöin eri pisteitä aloitettujen ketjujen välinen varianssi on vakaantunut.

Tällä diagnostiikalla on kuitenkin ongelmansa ja rajoitteensa. Se saattaa virheellisesti diagnosoida konvergoituneen ketjun esimerkiksi jos ketjulla on pitkät hännät. Sen takia käytetäänkin mielummin muita diagnostiikka keinoja. Esimerkiksi *Stan* käyttää korjattua \hat{R} diagnostiikkaa. [Veh+19]

3.4.2 ESS

Toinen hyödyllinen diagnostiikka MCMC-menetelmissä on niin sanottu *effective sample size* (*ESS*), joka mittaa sitä kuinka monta efektiivisesti riippumatonta otosta ketjussa on. Tämä tarkoittaa siis sitä, että se mittaa kuinka paljon ketjun autokorrelaatio vaikuttaa keskivirheeseen verrattuna täysin riippumattomiin otoksiin.

Määritelmä 3.35. ESS lasketaan kaavalla

$$(3.36) \quad \hat{n}_{\text{eff}} = \frac{mn}{1 + 2 \sum_{t=1}^T \hat{\rho}_t}$$

jossa

$$(3.37a) \quad \hat{\rho}_t = 1 - \frac{V_t}{2\hat{\sigma}^+}$$

$$(3.37b) \quad V_t = \frac{1}{m(n-t)} \sum_{j=1}^m \sum_{i=t+1}^n (\psi_{ij} - \psi_{i-t,j})^2$$

Kaavan (3.37a) $\hat{\sigma}^+$ saadaan kaavasta (3.33). Termissä $\sum_{t=1}^T \hat{\rho}_t$ autokorrelaatioita summaataan, kunnes kahden peräkkäisen kovariaatin summa on negatiivinen [Gey92].

Luku 4

Laajempi esimerkki

Tarkastellaan vielä lopuksi laajempaa esimerkkiä. Tarkastellaan normaalia lineaarista regressiomallia. Käytetään R:stä löytyvää `airquality` aineistoa New Yorkin ilmanlaadusta. Sovitetaan aineistoon bayesilainen lineaarinen malli

$$(4.1) \quad \text{Ozone} = \beta_0 + \beta_1 \text{Solar.R} + \beta_2 \text{Wind}$$

Sovitetaan tämä malli Gibbsin otanta-algoritmin avulla. Sitä varten meidän on ensiksi määriteltävä marginaaliset ehdolliset jakaumat parametreille.

Määritellään ensiksi malli. Merkitään $\tau = 1/\sigma^2$, $\theta = (\beta_0, \beta_1, \beta_2, \tau)$

$$(4.2) \quad \begin{aligned} y_i | \beta_0, \beta_1, \beta_2, \tau &\sim N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau) \\ \beta_0 | \mu_0, \tau_0 &\sim N(\mu_0, 1/\tau_0) \\ \beta_1 | \mu_1, \tau_1 &\sim N(\mu_1, 1/\tau_1) \\ \beta_2 | \mu_2, \tau_2 &\sim N(\mu_2, 1/\tau_2) \\ \tau | \alpha, \gamma &\sim \text{Gamma}(\alpha, \gamma) \end{aligned}$$

Muodostetaan uskottavuusfunktio

$$(4.3) \quad L(y|\theta) = \prod_{i=1}^N N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau)$$

Posterioirijakauman tiheysfunktio on siten laskettavissa verrannollisuudella

$$(4.4) \quad p(\theta|y) \propto p(\beta_0)p(\beta_1)p(\beta_2)p(\tau) \prod_{i=1}^N N(\beta_0 + \beta_1 x_i + \beta_2 x_i, 1/\tau)$$

Tästä saadaan sitten johdettua marginaaliset jakaumat otanta-algoritmia varten

$$\begin{aligned}
(4.5) \quad & \beta_0 | \beta_1, \beta_2, \tau_0, \tau, \mu_0, x, y \sim N \left(\frac{\tau_0 \mu_0 + \tau \sum_{i=1}^N (y_i - \beta_1 x_{i1} - \beta_2 x_{i2})}{\tau_0 + \tau N}, \frac{1}{\tau_0 + \tau N} \right) \\
& \beta_1 | \beta_0, \beta_2, \tau_1, \tau, \mu_1, x, y \sim N \left(\frac{\tau_1 \mu_1 + \tau \sum_{i=1}^N (y_i - \beta_0 - \beta_2 x_{i2}) x_{i1}}{\tau_1 + \tau \sum_{i=1}^N x_{i1}^2}, \frac{1}{\tau_1 + \tau \sum_{i=1}^N x_{i1}^2} \right) \\
& \beta_2 | \beta_0, \beta_1, \tau_2, \tau, \mu_2, x, y \sim N \left(\frac{\tau_2 \mu_2 + \tau \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{i1}) x_{i2}}{\tau_2 + \tau \sum_{i=1}^N x_{i2}^2}, \frac{1}{\tau_2 + \tau \sum_{i=1}^N x_{i2}^2} \right) \\
& \tau | \beta_0, \beta_1, \beta_2, \alpha, \gamma, x, y \sim \text{Gamma} \left(\alpha + \frac{N}{2}, \gamma + \frac{N}{2} \sum_{i=1}^N (y_i - \beta_0 - \beta_1 x_{i1} - \beta_2 x_{i2})^2 \right)
\end{aligned}$$

Asetetaan hyperparametrit $\mu_0 = 80, \mu_1 = 0, \mu_2 = -5, \tau_0 = 1/50, \tau_1 = 1/50, \tau_2 = 1/50, \alpha = 5, \gamma = 0.01$. Parametrit on valittu sen mukaan, että ne asettavat jakauman moodin lähelle arvioitua sijaintia ja toisaalta eivät ole kovin informatiivisia vaan paksu häntäisiä. Simuloidaan nyt tästä Gibbsin otanta-algoritmillä yhtälöitä 4.5 käyttäen 8 ketjua, kunkin pituus 2 000. Burnin-periodi olkoot 1 000. Yhteensä siis meillä on 16 000 otosta.

θ	Mean	SD	2.5%	25%	50%	75%	97.5%
β_0	78.89544	5.61842	67.97969	75.14744	78.89385	82.64874	89.86483
β_1	0.09675	0.02263	0.05196	0.08130	0.09688	0.11218	0.14106
β_2	-5.48880	0.51291	-6.48407	-5.83627	-5.49158	-5.13095	-4.48973
τ	0.00177	0.00023	0.00136	0.00161	0.00176	0.00192	0.00226


Taulukko 4.1: Tulokset regressiosta

θ	\hat{R}	\hat{n}_{eff}
β_0	1.00	778
β_1	1.00	1177
β_2	1.01	902
τ	1.00	7656

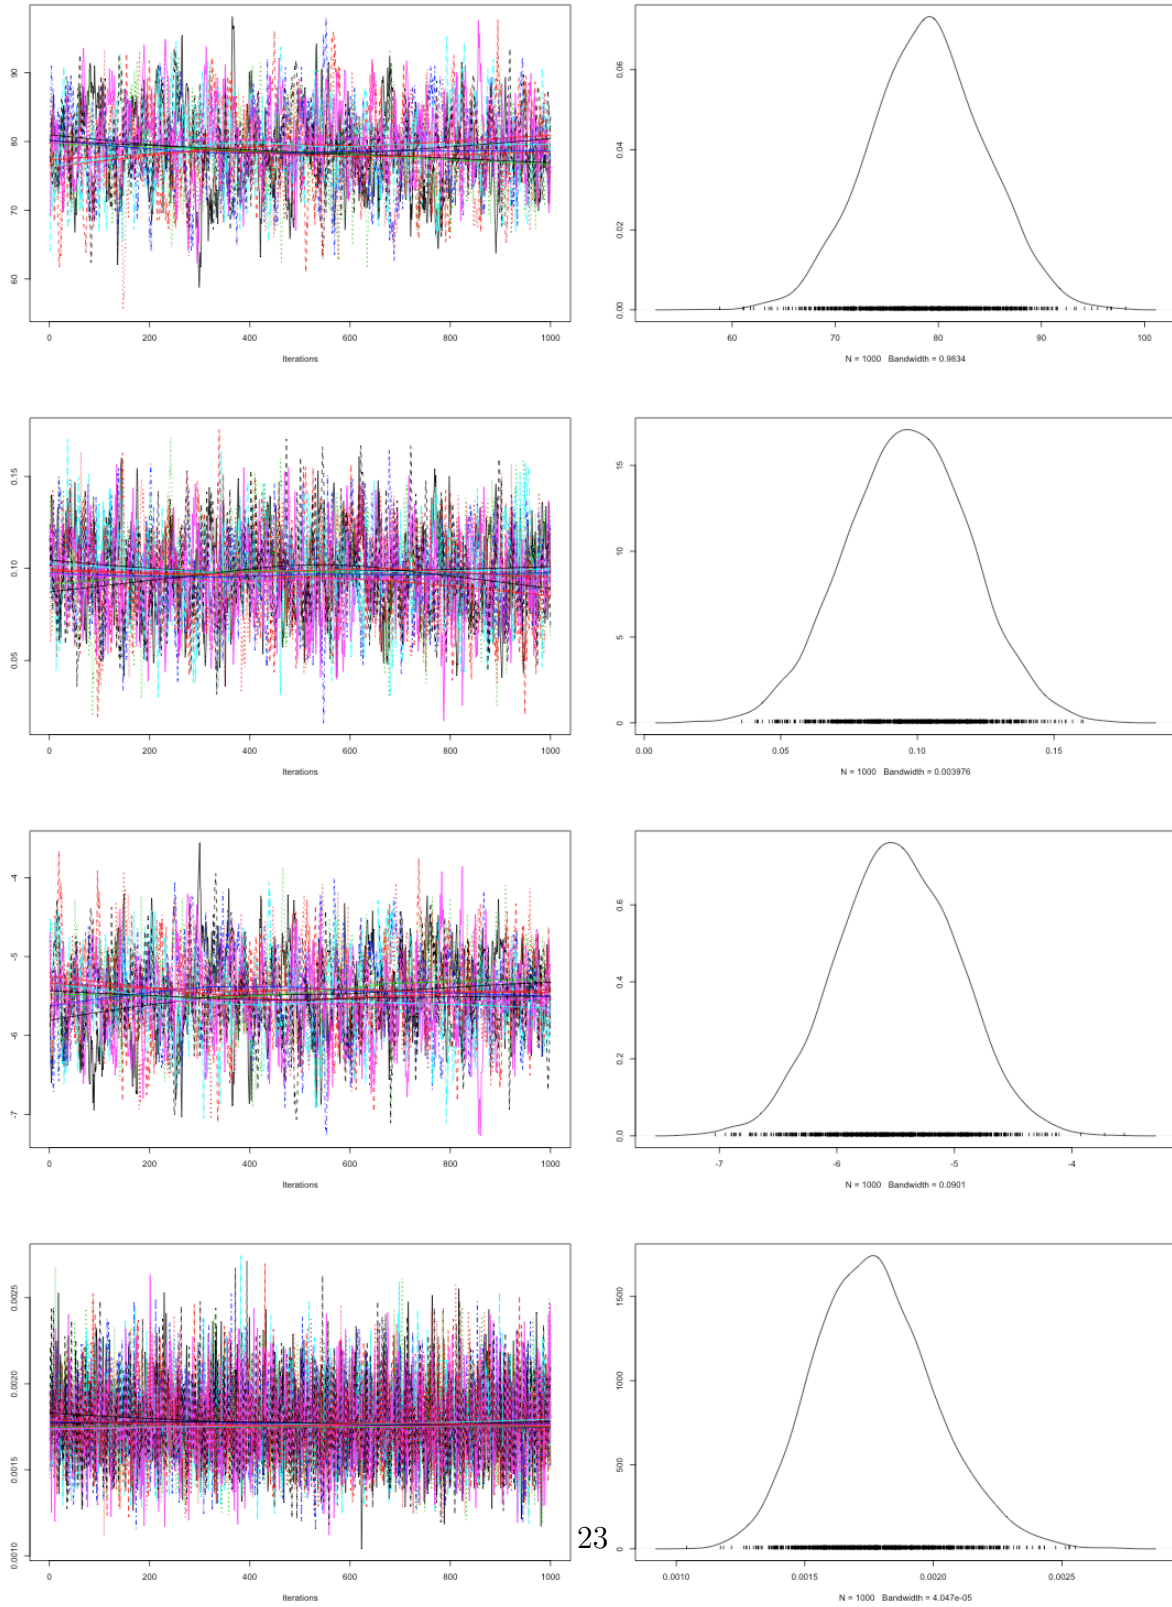
Taulukko 4.2: Diagnostiikka

Taulukoissa 4.1 ja 4.2 nähdään tulokset ja MCMC-diagnostiikat, joista puhuttiin aiemmin. Nähdään, että ketjut näyttäisivät konvergoituneen, mikä ei sinänsä ihmetytä lainkaan, sillä simulaatio määrämme on valtava. Yhteensä burn-in periodin jälkeen otoksia on 8000.

Mielenkiintoista on nähdä, että kuvassa 4.2 ketju parametrille $1/\tau$ on aivan ernäköinen kuin muille parametreille. Otoksia on yhtä paljon kaikissa, mutta parametrin $1/\tau$ ketju näyttää siltä, että otoksia olisi enemmän. Tämä toki nähdään myös \hat{n}_{eff} estimaatista.



Kuva 4.1: Esimerkin lineaarisen regression tulos, vasemmalla *Solar.R* -akselilla ja oikealla *Wind*. Punainen viiva on posteriori odotusarvolla piiretty regressioviiva ja vihreä on vertailun vuoksi PNS-mentelmällä sovitettu suora. Siniset ovat sovitteita parametrien eri ehdotus arvoilla.



Kuva 4.2: Esimerkin ketjut ja parametrien posteriori tiheydet

Luku 5

Loppusanat

Olemme nyt tarkastelleet perusajatuksia MCMC-menetelmistä. Kävimme läpi hieman teoriaa, esittelimme algoritmit ja kokeilimme sellaista käytännön tilanteessa. Kuitenkin olemme vain raapaisseet pintaa. Käyttämämme algoritmit ovat monessa mielessä erittäin rajoittuneita. Gibbsin otanta-algoritmissa meidän tulee tuntea marginaalijakaumat, ja Metropolis–Hastingsin algoritmissa voi olla välillä hidas konvergoitumaan.

Tärkeitä laajennuksia, jotka korjaavat edellisessä kappaleessa mainitsemani ongelmat, on myöhemmin kehitetyt tehokkaammat MCMC-metodit. Tärkeimpänä *Hamiltonian Monte Carlo* eli HMC. Se pyrkii vähentämään tarvittavien otosten määrää, joka tarvitaan tarpeeksi tarkan posterioriestimaatin saamiseksi, sillä menetelmä vähentää autokorrelaatiota tilojen välillä.

Ohitimme myös useita asioita liittyen Markovin ketjuihin. Markovin ketjujen matematiikka ei ole kovin vaikeaa käytännössä, mutta monet todistukset ovat työläisiä ja vaativat matematiikkaa, joka ylittää tämän tutkielman laajuuden.

Kuitenkin MCMC-menetelmät ovat mullistaneet maailmaa muunmuassa koneoppimis menetelmien massakaupallistumisen myötä. Ne ovat myös tehneet tieteestä luotettavampaa mahdollistamalla bayesiläisen tilastotieteen uuden nousun. Varsinkin replikaatiokriisin jälkeisessä maailmassa se on arvokas kontribuutio.

Paljon on kuitenkin vielä tutkittavaa. Suurista viimeaikaisista loikista huolimatta, MCMC-menetelmtä eivät voita vielääkään nopeudessa perinteisiä tilastollisia menetelmiä, joten uusia ja nopeampia algoritmeja olisi vielä kehiteltävä ja helppokäyttöisyyttä parannettava, jotta MCMC-menetelmät saavuttavat täyden potentiaalinsa.

Kirjallisuus

- [Dur10] Rick Durrett. *Probability: Theory and Examples*. 4. painos. Cambridge Series in Statistical and Probabilistic Mathematics. Cambridge University Press, 2010. DOI: 10.1017/CB09780511779398.
- [Gel92] Donald Rubin Gelman Andrew. “Inference from Iterative Simulation using Multiple Sequences”. *Statistical Science* 7 (1992), s. 457–511.
- [Gel98] Stephen Brooks Gelman Andrew. “General Methods for Monitoring Convergence of Iterative Simulations”. *Journal of Computational and Graphical Statistics* (joulukuu 1998). URL: <http://www.stat.columbia.edu/~gelman/research/published/brooksgelman2.pdf>.
- [Gey92] Charles Geyer. “Practical Markov Chain Monte Carlo”. *Statistical Science* 7.4 (1992), s. 473–483.
- [Kle13] A. Klenke. *Probability Theory: A Comprehensive Course*. Universitext. Springer London, 2013. ISBN: 9781447153603.
- [Koi09] Petri Koistinen. *Computational Statistics*. 2009.
- [Met53] Nicholas Metropolis. “Equation of state calculations by fast computing machines” (1953).
- [Pii] Petteri Piiroinen. *Stokastiset prosessit luentomoniste*.
- [RC05] Christian P. Robert ja George Casella. *Monte Carlo Statistical Methods (Springer Texts in Statistics)*. Berlin, Heidelberg: Springer-Verlag, 2005. ISBN: 0387212396.
- [Gel+13] Andrew Gelman et al. *Bayesian Data Analysis*. 3. painos. 2013. ISBN: 978-1-4398-4095-5.
- [Veh+19] Aki Vehtari et al. “Rank-normalization, folding, and localization: An improved \hat{R} for assessing convergence of MCMC”. *arXiv e-prints*, arXiv:1903.08008 (maaliskuu 2019), arXiv:1903.08008. arXiv: 1903.08008 [stat.CO].